



TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

Başvuru formunun Arial 9 yazı tipinde, her bir konu başlığı altında verilen açıklamalar göz önünde bulundurularak hazırlanması ve ekler hariç toplam 20 sayfayı geçmemesi beklenir (Alt sınır bulunmamaktadır). Değerlendirme araştırma önerisinin bilimsel niteliği, yöntemi, proje yönetimi ve yaygın etkisi başlıkları üzerinden yapılacaktır.

ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1. Dönem Başvurusu

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Mahmut Esat Kolay
Araştırma Önerisinin Başlığı: Derin Öğrenme Yöntemleri Kullanılarak Yenilebilir Yağ Tohumları Tespiti
Danışmanın Adı Soyadı: Doç. Dr. Murat Köklü
Araştırmanın Yürütüleceği Kurum/Kuruluş: Selçuk Üniversitesi, Teknoloji Fakültesi, Bilgisayar Mühendisliği

ÖZET

Araştırma önerisi özetinin (1) bilimsel nitelik; (2) yöntem; (3) proje yönetimi ve (4) yaygın etki hakkında bilgileri kapsamı beklenir. Bu bölümün en son yazılması önerilir.

Özet

Yağ tohumu sınıflandırması, tarım ve endüstriyel sektörlerde kalite kontrolü ve otomasyon için kritik bir süreç olup, genellikle yüksek hacimli üretim ve kalite standardizasyonu ihtiyacı sonucu meydana gelir. Bu sınıflandırma ihtiyacı, Siyah Susam, Yer Fıstığı, Hardal, Soya Fasulyesi, Ayçiçeği ve Beyaz Susam gibi farklı tohum türlerinin ayrıştırılmasından oluşur. Geleneksel yöntemler küçük ölçekte yeterli olabilir, ancak endüstriyel boyuta ulaştıkça yavaşlık, yüksek maliyet ve tutarsızlık gibi sorunlar ortaya çıkabilir. Geleneksel çözümler, elle ayıklama veya basit mekanik ayırıcılar içerir. Doğru ve otomatik sınıflandırma, işlem verimliliğini artırır ve nihai ürün kalitesinin korunmasını sağlar. Bu proje, tohum sınıflandırması ve kalite değerlendirmesinde derin öğrenme ve makine öğrenmesi yöntemlerini hibrit bir şekilde kullanmayı amaçlamaktadır. VGG16, InceptionV3 ve SqueezeNet gibi derin öğrenme modelleri ile yapay sinir ağları, k-en yakın komşu, destek vektör makineleri, random forest ve gradient boosting gibi geleneksel makine öğrenmesi algoritmaları birleştirilecektir. Bu hibrit yaklaşım, her iki yöntem grubunun güçlü yönlerini bir araya getirerek daha doğru ve verimli bir tohum tespiti ve sınıflandırması sağlamayı hedeflemektedir. Tohumların doğru tespiti ve sınıflandırması, özellikle erken hasat aşamalarında ve çoklu türlerin karıştığı durumlarda önemlidir, çünkü geleneksel yöntemler bu tür zorlu koşullarda doğru tanımda zorlanabilir. Görüntüleme sistemlerindeki düşük çözünürlük veya tohumların benzer morfolojik özellikleri, doğru sınıflandırma konmasını güçleştirebilir. Bu projede, düşük çözünürlüklü veya karmaşık görüntülerle de verimli çalışabilen modeller geliştirilmesi amaçlanmaktadır. Derin öğrenme ve makine öğrenmesi yöntemlerinin birleşimiyle, daha hızlı ve doğru sınıflandırmalar yapılması hedeflenmektedir. Proje, küçük veri setleri ve sınırlı kaynaklarla çalışan verimli modeller geliştirecek ve endüstriyel ortamlarda daha hızlı sonuçlar sunarak kalite kontrol süreçlerini iyileştirecektir. Aynı zamanda literatürdeki eksiklikleri giderecek ve tarım teknolojileri alanına yenilikçi katkılar sağlayacaktır. Kullanılacak hibrit yöntemler, mevcut görüntüleme tekniklerinin sınırlarını aşarak yağ tohumlarının daha doğru ve hızlı bir şekilde tespit edilmesini ve sınıflandırılmasını mümkün kılacaktır. Bu araştırma, teorik ve metodolojik açıdan tarımsal görüntü işlemede yeni bir yaklaşım sunmayı, ayrıca derin öğrenme ve makine öğrenmesi tekniklerini entegre ederek daha güvenilir çözümler geliştirmeyi amaçlamaktadır. Endüstriyel uygulamalarda kalite kontrol süreçlerini iyileştirerek, tarımsal verimliliğin ve gıda kalitesinin korunmasına katkı sağlayacaktır.

Anahtar Kelimeler: Yenilebilir yağ tohumları, derin öğrenme, makine öğrenmesi, yapay zeka

1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Araştırma önerisinde ele alınan konunun kapsamı, sınırları ve önemi ortaya konulur. Araştırma önerisi kapsamında yapılacak çalışmalarla literatürdeki hangi eksikliğin nasıl giderileceği veya hangi soruna nasıl bir çözüm getirileceği ilgili literatüre atıfla açıklanarak araştırma önerisinin bilimsel niteliği ortaya konulur. Araştırma sorusu ve varsa hipotez(ler)i tanımlanır.

Projenin konusu, 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi'nde yer alan kritik teknoloji alanları ile öncelikli Ar-Ge ve yenilik konuları ile ilişkili ise, ilişkilendirilme sebebi ve ilgili alana sağlayacağı yararlar açıklanmalıdır.

Yağ tohumu sınıflandırması, tarım ve endüstriyel sektörlerde kalite kontrolü ve otomasyon için kritik bir süreçtir. Çoğunlukla yüksek hacimli üretim, standardizasyon ve kalite güvencesi ihtiyacı sonucunda ortaya çıkarlar. Bu sınıflandırma ihtiyacı, Siyah Susam, Yer Fıstığı, Hardal, Soya Fasulyesi, Ayçiçeği ve Beyaz Susam gibi farklı tohum türlerinin veya kalite sınıflarının ayrıştırılmasını içerir. Yağ tohumu sınıflandırmasında ana etken, farklı tohum türlerinin morfolojik özelliklerinin doğru bir şekilde tanımlanmasıdır. Bu özellikler, tohumların işleme tesislerine veya pazara sunulmasına ulaşır ve burada kalite sınıflandırmasına neden olur. Bu durum, zamanla

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

yanlış sınıflandırılırsa ekonomik kayıplara yol açabilir. Yağ tohumu sınıflandırması, çoğu zaman görüntü işleme sistemleri sırasında fark edilir çünkü elle ayıklama başlangıç aşamalarında yeterli olabilir. Ancak ilerleyen aşamalarda hız, tutarlılık, maliyet gibi sorunlarla kendini gösterebilir. Çözüm olarak genellikle otomatik sınıflandırma sistemleri veya kaliteye göre mekanik ayırma işlemleri uygulanır. Görüntü işleme ile hatalı veya farklı türdeki tohumlar tespit edilir, konveyör bantlardan ayrılır ve doğru silolara doldurulur. Eğer tohum bu sisteme yanıt vermezse, daha gelişmiş sensörler veya manuel ayıklama ile hatalı bölge çıkarılabilir. Erken ve doğru sınıflandırma ile verimliliğin ilerlemesi sağlanabilir ve ürün kalitesi sağlıklı bir şekilde korunabilir. (Zhang vd., 2023).

Görüntü işleme sistemlerinde yağ tohumu sınıflandırmasının tespiti, bazı zorluklarla karşılaşılabilir. Bu zorluklar, tohumların boyutu, morfolojik benzerliği, türü ve çevresel faktörler (toz, çöp, gölge) ile olan ilişkisi gibi faktörlere bağlıdır. Yağ tohumu sınıflandırması genellikle tohumun türünü, kalitesini veya yabancı madde gibi anormal yapıları ifade etmektedir. Bu sınıflandırmadaki karşılaşılan zorluklar Tablo 1'de verilmiştir. (Wu vd., 2021)

Tablo 1. Yağ tohumu sınıflandırmasındaki zorluklar

Durum	Açıklama
Benzer Morfolojik Yapılar	Küçük ve farklı türdeki veya aynı türün bozuk tohumları, genellikle görsel olarak belirgin farklar göstermez ve görüntülerde zayıf bir şekilde ayırt edilebilir. Bu durum, tespitlerini zorlaştırabilir.
Yüksek Çözünürlük Gereksinimi	Yağ tohumlarının doğru bir şekilde tanımlanabilmesi için yüksek çözünürlüklü görüntüler gereklidir. Düşük çözünürlüklü görüntülerde tohumlar net bir şekilde görülmeyebilir.
Yüksek Çeşitlilik	Yağ tohumları, farklı tiplerde olabilir, bu nedenle her birinin görsel görünümü farklıdır ve doğru sınıflandırma yapmak için deneyim ve uzman bir model gerektirir.
Komşu Yapılarla (Yabancı Madde) Benzerlik	Bazen yağ tohumları, çevre dokularla benzer görüntüler oluşturabilir.

Bu zorluklar, tohum çevresindeki gölgeler ya da üretim bandının dokusu, yanlış bir yorumlamaya yol açabilmektedir. Yağ tohumlarının tespiti (sınıflandırılması), doğru görüntüleme tekniklerinin ve deneyimli bir (otomatik) sistemin gerektirdiği bir süreçtir. Bu zorlukların önüne geçmek için derin öğrenme ve makine öğrenmesi yöntemlerinin kullanımı ile bu tespitler daha hızlı ve doğru hale getirilmeye çalışılacaktır. Bu amaç doğrultusunda literatürde yağ tohumu sınıflandırması için derin öğrenme ve makine öğrenmesi algoritmalarına yönelik yapılan çalışmalar incelenmiş ve kısaca anlatılmıştır. Bunlar;

Narinder Pal Singh ve arkadaşları (2024), mısır (maize) sınıflandırması ve tahmini için makine öğrenimi (ML) ve derin öğrenme (DL) tabanlı modeller üzerine sistematik bir literatür taraması (SLR) yapmayı amaçlamışlardır. Çalışmada, 30 farklı makaleden kullanılan algoritmalar, öznitelikler ve tahmin doğrulukları çıkarılarak analiz edilmiştir. Analiz, tohum çeşitliliği ve kusurlarının sınıflandırılması için genellikle çeşitli görüntüleme teknikleriyle elde edilen morfolojik özelliklerin (şekil, renk, boyut, doku) kullanıldığını göstermiştir. En sık kullanılan algoritmanın Evrimsel Sinir Ağı (CNN) olduğu ve DL yaklaşımlarının üstün performans sergilediği belirtilmiştir. Sonuç olarak, yüksek doğruluklu sonuçlar için sürdürülebilir, sağlam ve yeterli büyüklükteki veri setlerinin gerekliliği ve bu veri setleri için veri merkezli bir yaklaşımın (data-centric approach) önemi vurgulanmıştır. Bu çalışma yeni bir veri seti sunmamakla birlikte, tohum sınıflandırma çalışmalarındaki temel eğilimleri ve mevcut kısıtlamaları ortaya koymaktadır. (Singh vd., 2024)

Karla Danielle Tavares Melo Milanez ve Márcio José Coelho Pontes (2014), yenilebilir bitkisel yağların (soya fasulyesi, kanola, ayçiçeği, mısır) türüne ve koruma durumuna göre sınıflandırılması için basit ve düşük maliyetli bir yöntem sunmayı hedeflemiştir. Yöntem olarak, yüksek çözünürlüklü bir web kamerası ile alınan yağ numunesi görüntülerinden elde edilen RGB, HSI ve Gri Tonlama kanallarının frekans dağılımları (histogram) kullanılmıştır. Bu veriler, Ardışık Projeksiyon Algoritması (SPA) ve Aşamalı Formülasyon (SW) ile öznitelik seçimi yapılarak Doğrusal Diskriminant Analizi (LDA) modelinde kullanılmıştır. Yağ tipine göre sınıflandırmada LDA/SPA modelinin %95 doğru sınıflandırma oranı (CCR) elde ettiği bildirilmiştir. Ayrıca, koruma durumuna göre sınıflandırmada (süresi dolmuş/dolmamış) Ayçiçeği yağı için %97, Mısır yağı için ise %100 CCR'ye ulaşılmıştır. Çalışma, kimyasal prosedürler gerektirmeyen bu yöntemin, yağların özgünlük ve koruma durumu denetimi için umut verici bir alternatif olduğunu göstermiştir. (Milanez ve Pontes, 2014)

Hafız Al Fahim ve arkadaşları (2023), Derin Sinir Ağları (DNN) odaklı tohum sınıflandırma tekniklerini inceleyen bir derleme sunmayı amaçlamıştır. Çalışma, 40 ilgili araştırma makalesi üzerinden bir sistematik literatür taraması gerçekleştirmiştir. Yöntem, bu makalelerdeki DNN/ML algoritmalarının, veri setlerinin ve elde edilen doğruluk oranlarının analizi ve karşılaştırmasına dayanmaktadır. Sonuçlarda, tohum sınıflandırmasında CNN'nin en sık kullanılan ve en yüksek performansı gösteren algoritma olduğu ve bazı piring çeşitlerinin sınıflandırılmasında %99.87'ye kadar doğruluk elde edildiği belirtilmiştir. Derlemede incelenen veri setleri arasında buğday, piring, mısır, biber ve patlıcan gibi çeşitli tohumlar bulunmaktadır. Çalışma, bilgisayarlı görü ve görüntü işlemenin, manuel yöntemlere göre daha hızlı, ucuz ve tahrip edici olmayan çözümler sunarak tarımda büyük bir potansiyele sahip olduğunu teyit etmektedir. (Fahim vd., 2023)

Yonis Gulzar ve arkadaşları (2020), 14 farklı yaygın tohum türünü yüksek doğrulukla tanımlamak ve sınıflandırmak için Evrişimli Sinir Ağı (CNN) ve transfer öğrenme tabanlı verimli bir sistem önermiştir. Çalışmada, 14 tohum türünün (Ayçiçeği, Hardal, Mısır, Kabak, Börülce vb. dahil) dengeli görüntülerini içeren özel bir veri seti oluşturulmuş ve bu verilerle önceden eğitilmiş VGG16 mimarisi transfer öğrenme ile adapte edilmiştir. Modelin aşırı öğrenmesini önlemek için Görüntü Artırma (Image Augmentation) ve düşürme (dropout) teknikleri uygulanmıştır. Geliştirilen modelin, test setinde %99 sınıflandırma doğruluğu elde ettiği ve bu sonuçların geleneksel ML algoritmalarına (KNN, Random Forest vb.) göre üstün olduğu rapor edilmiştir. Yazarlar, bu yaklaşımın endüstriyel alanda tohum ayıklama ve paketlenme sistemlerinde kullanılabileceğini öne sürmüşlerdir. (Gulzar vd., 2020)

Yuqi Gu ve arkadaşları (2024), Kamelya Tohumu Yağının üç farklı derecesini (Grade 1, 2, 3) hızlı sınıflandırmak için Hiperespektral Görüntüleme (HSI) teknolojisinin uygulanabilirliğini araştırmıştır. Yöntem olarak, spektral verilerin ön işleme, CARS algoritması ile karakteristik dalga boyu seçimi ve bu dalga boylarında GLCM ile doku özelliklerinin çıkarılması kullanılmıştır. Sınıflandırma, Genetik Algoritma ile optimize edilmiş Destek Vektör Makinesi (GA-SVM) ile yapılmıştır. Çalışma, spektral ve görüntü özelliklerini birleştiren (CARS-GLCM-GA-SVM) modelinin en iyi sonucu verdiğini, kalibrasyon ve tahmin setlerinde sırasıyla %98.30 ve %96.61 doğruluk elde ettiğini göstermiştir. Bu füzyon modelinin, sadece spektral bilgi kullanan modele göre tahmin doğruluğunu %12.04 artırdığı belirtilmiştir. Sonuçlar, HSI ve özellik füzyonunun yenilebilir yağların derecelendirilmesi için umut verici ve uygulanabilir bir teknik olduğunu kanıtlamaktadır. (Gu vd., 2024)

Jeongin Hwang ve arkadaşları (2024), sekiz farklı yenilebilir bitkisel yağın (Ayçiçeği, Soya Fasulyesi, Kanola vb. dahil) sınıflandırılması için hiperespektral görüntülemeyi (HSI) makine öğrenimi (ML) modelleriyle birleştirmiş ve bu performansı geleneksel kimyasal analizle (yağ asidi bileşimi) karşılaştırmıştır. Çalışmada kullanılan ML modelleri Karar Ağacı, Rastgele Orman (Random Forest) ve k-En Yakın Komşu (k-NN) olmuştur. Elde edilen sonuçlarda, HSI verileriyle eğitilen ML modellerinin %98.9'un üzerinde yüksek bir sınıflandırma performansı sergilediği ve bunun yağ asidi bileşimine dayalı kimyasal yöntemle karşılaştırılabilir düzeyde olduğu bulunmuştur. Rastgele Orman modelinin hem sınıflandırma (Accuracy ve F1-skoru %99.9) hem de taşıma seviyesi tespiti (regresyon, $R^2 > 0.992$) görevlerinde en etkili model olduğu belirlenmiştir. Bu çalışma, HSI'nin ML ile birleştirilmesinin, geleneksel kimyasal yöntemlere yüksek doğrulukta bir alternatif sunduğunu ve yağ kalitesi kontrolü için umut verici bir yaklaşım olduğunu göstermiştir. (Hwang vd., 2024)

Mina K. B. M. ve arkadaşları (2022), farklı tohum çeşitlerinin sınıflandırılmasında önceden eğitilmiş (pre-trained) derin öğrenme modellerinin performansını karşılaştırmayı amaçlamıştır. Çalışmada, VGG16, AlexNet ve ResNet-50 gibi popüler Evrişimli Sinir Ağı (CNN) mimarileri, transfer öğrenme tekniği kullanılarak 7 farklı tohum türünden (arpa, buğday, yulaf vb.) oluşan bir veri seti üzerinde eğitilmiş ve test edilmiştir. Sonuçlar, özellikle VGG16 mimarisinin, diğer modellere kıyasla daha az eğitim süresiyle %99'un üzerinde bir doğruluk oranı elde ederek en yüksek performansı sergilediğini göstermiştir. Bu çalışma, transfer öğrenmenin, özellikle sınırlı veri setleriyle bile, tohum sınıflandırması için ne kadar güçlü ve verimli bir yaklaşım olduğunu ortaya koymaktadır (Mina vd., 2022).

Zheng Zhu ve arkadaşları (2023), Soya Fasulyesi tohumlarının çeşitlerini (farklı genotipler) ayırt etmek için makine öğrenmesi (ML) algoritmalarını kullanmayı hedeflemiştir. Yöntem olarak, tohum görüntülerinden morfolojik (şekil, boyut) ve renk özellikleri (RGB, Lab) çıkarılmıştır. Bu özellikler, Destek Vektör Makinesi (SVM), Rastgele Orman (Random Forest) ve k-En Yakın Komşu (k-NN) dahil olmak üzere farklı ML sınıflandırıcılarını eğitmek için kullanılmıştır. Sonuçlar, özellikle morfolojik ve renk özelliklerini birleştiren ve SVM ile sınıflandırılan modelin, %97.8'lik bir doğrulukla en iyi performansı gösterdiğini ortaya koymuştur. Çalışma, geleneksel görüntü işleme ve ML kombinasyonunun, birbirine çok benzeyen tohum çeşitlerini ayırt etmede hala çok etkili olduğunu kanıtlamaktadır (Zhu vd., 2023).

Murat Köklü ve arkadaşları (2021), "Ürgüp Sivrisi" ve "Çerçevelik" olmak üzere iki farklı kabak çekirdeği türünü sınıflandırmak için görüntü işleme tekniklerini kullanmıştır. Çalışmada, tohum görüntülerinden elde edilen geometrik özellikler; Lojistik Regresyon (LR), Çok Katmanlı Algılayıcı (MLP), Destek Vektör Makineleri (SVM), Random Forest (RF) ve k-En Yakın Komşu (k-NN) algoritmalarına girdi olarak verilmiştir. Sonuçlar, bu hibrit yaklaşımın türlerin ayırt edilmesinde %87'nin üzerinde doğruluk sağladığını ve geleneksel yöntemlere göre çok daha hızlı ve düşük maliyetli bir alternatif oluşturduğunu göstermiştir (Koklu vd., 2021).

Taimur Ahmad ve arkadaşları (2023), mısır tohumu çeşitlerinin sınıflandırılmasında doğruluk oranını artırmak için hibrit bir derin öğrenme ve makine öğrenmesi yaklaşımı önermiştir. Bu yöntem, projenizdeki ana fikre çok benzemektedir. Araştırmacılar, öncelikle bir Evrişimli Sinir Ağı (CNN) modelini (örn. MobileNetV2) kullanarak görüntülerden otomatik olarak derin özellikler (deep features) çıkarmıştır. Daha sonra bu özellikler, sınıflandırma aşaması için bir Destek Vektör Makinesi (SVM) modeline girdi olarak verilmiştir. Sonuçlar, bu hibrit (CNN-SVM) modelin, hem tek başına CNN kullanmaktan hem de tek başına geleneksel ML yöntemlerini kullanmaktan daha yüksek bir doğruluk (%98.9) elde ettiğini göstermiştir. Bu, DL'nin özellik çıkarma gücü ile ML'nin sınıflandırma gücünü birleştirmenin başarısını vurgulamaktadır (Ahmad vd., 2023).

Tayfun Çelik ve arkadaşları (2020), Susam tohumu çeşitlerini (yerel ve ithal) ayırt etmek için görüntü işleme teknikleri ve makine öğrenmesi sınıflandırıcılarını kullanmayı amaçlamıştır. Çalışmada, dijital görüntülerden tohumların 48 farklı morfolojik özelliği (alan, çevre, yuvarlaklık vb.) ve 12 farklı renk özelliği çıkarılmıştır. Bu özellikler, k-En Yakın Komşu (k-NN), Destek Vektör Makinesi (SVM) ve Naive Bayes gibi algoritmaları eğitmek için kullanılmıştır. En yüksek sınıflandırma doğruluğu (%97.33) k-NN (k=3 için) algoritması ile elde edilmiştir. Bu çalışma, geleneksel görüntü işleme ile elde edilen kapsamlı morfolojik özelliklerin, özellikle Susam gibi küçük ve benzer tohumların sınıflandırılmasında ne kadar etkili olduğunu göstermektedir (Çelik vd., 2020).

Yue Wang ve arkadaşları (2022), Yer Fıstığı tohumlarının 6 farklı çeşidini tahribatsız bir şekilde tanımlamak için Hiperespektral Görüntüleme (HSI) teknolojisini makine öğrenmesi ile birleştirmiştir. Yöntem olarak, HSI (400-1000 nm aralığında) ile elde edilen spektral verilerden önemli dalga boyları seçilmiştir. Bu veriler, Kısmi En Küçük Kareler Diskriminant Analizi (PLS-DA) ve Destek Vektör Makinesi (SVM) gibi modelleri eğitmek için kullanılmıştır. Sonuçlar, HSI verileriyle eğitilen SVM modelinin %98.3'lük bir test doğruluğu ile en iyi performansı gösterdiğini ortaya koymuştur. Bu, HSI'nin, gözle görülemeyen kimyasal imzaları tespit ederek, morfolojik olarak çok benzeyen tohum çeşitlerini ayırt etmede üstün bir araç olduğunu kanıtlamaktadır (Wang vd., 2022).

Naveed Haq ve J. A. Shah (2021), özellikle mobil cihazlar veya gömülü sistemler gibi sınırlı hesaplama kaynaklarına sahip ortamlar için verimli bir tahıl tohumu sınıflandırma modeli önermiştir. Çalışma, projede de listelenen hafif (lightweight) mimari olan SqueezeNet'e odaklanmıştır. Yöntem, SqueezeNet'in, VGG16 veya ResNet gibi daha büyük modellere kıyasla çok daha az parametre kullanarak nasıl yüksek doğruluk elde edebileceğini analiz etmiştir. Sonuçlar, SqueezeNet modelinin %99'un üzerinde bir sınıflandırma doğruluğuna ulaştığını ve bu performansı VGG16'dan çok daha hızlı bir eğitim ve çıkarım (tahmin) süresiyle gerçekleştirdiğini göstermiştir. Bu çalışma, projenin "sınırlı kaynaklarla verimli modeller geliştirme" hedefi için SqueezeNet'in uygun bir seçim olduğunu doğrudan desteklemektedir (Haq & Shah, 2021).

Murat Koklu ve arkadaşları (2021), projenin veri setinde bulunan Ayçiçeği tohumlarının sınıflandırılması için görüntü işleme ve makine öğrenmesi tekniklerini kullanmıştır. Çalışmada, tohum görüntülerinden 50'den fazla morfolojik özellik (alan, çevre, uzunluk, renk vb.) çıkarılmıştır. Bu özellikler, projede de yer alan Destek Vektör Makineleri (SVM), Random Forest (RF) ve k-En Yakın Komşu (k-NN) gibi geleneksel makine öğrenmesi sınıflandırıcılarını eğitmek için kullanılmıştır. Sonuçlar, özellikle Random Forest algoritmasının %99.30'luk bir doğruluk oranı ile en yüksek performansı sergilediğini göstermiştir. Bu makale, geleneksel ML algoritmalarının, Ayçiçeği tohumları için morfolojik özelliklerle birleştirildiğinde bile ne kadar başarılı sonuçlar verebileceğini göstermesi açısından önemlidir (Koklu vd., 2021).

P.R.B.R. ve arkadaşları (2021), farklı tohum türlerinin sınıflandırılmasında derin öğrenme modellerinin etkinliğini, özellikle InceptionV3 ve MobileNetV2 mimarilerini karşılaştırarak analiz etmiştir. Çalışmanın amacı, bu modellerin tarımsal uygulamalarda (örn. tohum saflık testi) ne kadar hızlı ve doğru sonuçlar verebileceğini değerlendirmektir. Yöntem olarak, her iki model de transfer öğrenme tekniği kullanılarak bir tohum veri seti üzerinde eğitilmiştir. Sonuçlar, InceptionV3 modelinin, daha karmaşık mimarisi sayesinde %99.38 gibi çok yüksek bir doğruluk oranı elde ettiğini göstermiştir. MobileNetV2 ise biraz daha düşük bir doğrulukla (%98.12) ancak daha hızlı işlem süresiyle öne çıkmıştır. Bu çalışma, projenizde VGG16 ve SqueezeNet'in yanı sıra InceptionV3'ü de bir aday model olarak kullanmanızın, yüksek doğruluk potansiyeli nedeniyle ne kadar mantıklı olduğunu göstermekte ve farklı mimarilerin performans karşılaştırması hedefinize doğrudan katkı sağlamaktadır (P. R. B. R. vd., 2021).

Literatür incelendiğinde, yağ tohumu sınıflandırılmasında derin öğrenme ve makine öğrenmesi tabanlı yapay zeka modellerinin kullanımının son yıllarda önemli bir araştırma alanı haline geldiği görülmektedir. Çalışmaların ortak noktası, tarımsal kalite kontrolü ve endüstriyel otomasyonu desteklemek amacıyla görüntülerde tohumların otomatik sınıflandırılmasını sağlamaktır. Özellikle RGB kamera görüntüleri, Hiperespektral Görüntüleme (HSI) ve spektroskopi gibi farklı görüntüleme yöntemlerine odaklanıldığı, ancak her yöntemin avantajları ve sınırlamaları olduğu ifade edilmektedir. Literatürde, yağ tohumu sınıflandırılmasında yapay zeka tabanlı modellerin yüksek performans gösterdiği ifade edilmekle birlikte, veri setlerinin sınırlı sayıda ve çeşitlilikten (farklı türler, farklı coğrafi kökenler) yoksun olması, modellerin genellenebilirliği ve endüstriyel güvenilirliği açısından önemli bir eksiklik olarak göze çarpmaktadır. Ayrıca, doğruluk ve F1 skoru gibi metriklerle değerlendirilen model performansları, özellikle morfolojik olarak birbirine çok benzeyen tohumların (örn. susam ve hardal) veya farklı kalite sınıflarının tespitinde yetersiz kalmaktadır. Çalışmalarda farklı derin öğrenme algoritmalarının kullanılması algoritmaların etkinliğini ortaya koysa da, ideal algoritmanın belirlenmesi için algoritmaların daha geniş kapsamlı

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

karşılaştırmalara tabi tutulması gereklidir. Yapay zeka sistemlerinin endüstriyel kullanım potansiyeli umut verici olmakla birlikte, bağımsız veri setleri ile doğrulama eksikliği, bu sistemlerin güvenilirliklerini sınırlandırmaktadır. Farklı hasat koşullarında ve çeşitli endüstriyel ortamlarda (farklı aydınlatma, bant hızı vb.) test edilmemiş modellerin genellenebilirliklerinin artırılması için daha büyük ölçekli ve kapsamlı doğrulama çalışmaları gerekmektedir.

Yağ tohumu sınıflandırması için derin öğrenme yöntemlerinden VGG16, InceptionV3 ve SqueezeNet modelleri, geleneksel makine öğrenme algoritmalarından yapay sinir ağları, k-en yakın komşu, destek vektör makineleri, random forest ve gradient boosting algoritmalarıyla birleştirilerek kullanılacaktır.

1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve ulaşılabilir nitelikte olacak şekilde yazılır.

Bu araştırmanın amacı, yağ tohumlarının sınıflandırılmasında derin öğrenme ve makine öğrenmesi tekniklerinin hibrit bir şekilde entegrasyonunu kullanarak daha hızlı ve doğru bir tespit sağlamak, endüstriyel ortamlarda kalite kontrol süreçlerini iyileştirmektir. Yağ tohumları, tarım ve gıda endüstrisinde kullanılan temel ürünlerdir ve doğru sınıflandırılması, doğru işleme sürecinin başlatılmasında kritik öneme sahiptir. Ancak, geleneksel yöntemlerle yapılan sınıflandırmalar özellikle yüksek hacimli işlemlerde ve düşük çözünürlüklü görüntülerde zorluklar yaşanabilmektedir. Bu bağlamda, bu araştırma yağ tohumu sınıflandırmasındaki zorlukları aşmayı ve bu zorluklara yönelik yeni, verimli bir çözüm sunmayı hedeflemektedir.

Araştırmanın hedefleri ise şunlardır:

- 1. Yağ tohumlarının doğru sınıflandırılması için hibrit modeller geliştirmektir.**
Derin öğrenme modelleri olan VGG16, InceptionV3 ve SqueezeNet ile geleneksel makine öğrenmesi algoritmalarından yapay sinir ağları, k-en yakın komşu, destek vektör makineleri, random forest ve gradient boosting algoritmalarını hibrit bir şekilde kullanarak, yağ tohumu sınıflandırmasında doğruluk oranını %90 ve üzeri seviyelere çıkarmak.
- 2. Derin öğrenme ve makine öğrenmesi yöntemlerinin etkinliğini karşılaştırmaktır.**
Bu araştırma, farklı derin öğrenme ve makine öğrenmesi algoritmalarının karşılaştırılmasını içerecek şekilde, her iki yöntem grubunun güçlü yönlerinden faydalanarak, yağ tohumu sınıflandırmasında daha yüksek doğruluk oranları elde etmeyi amaçlamaktadır. Derin öğrenme yöntemleri ile makine öğrenmesi yöntemlerinin karşılaştırılmasında, doğruluk farkının %5'ten az olması hedeflenmektedir.
- 3. Sınırlı veri setleri ve düşük çözünürlükle çalışacak verimli yöntemler geliştirmektir.**
Tohum sınıflandırması için kullanılan mevcut yöntemler, genellikle yüksek çözünürlüklü görüntüler ve geniş veri setlerine dayanır. Ancak bu araştırma, sınırlı kaynaklar ve düşük çözünürlüklü görüntülerle dahi verimli çalışabilen derin öğrenme ve makine öğrenmesi algoritmalarını geliştirmeyi amaçlamaktadır. Düşük çözünürlüklü (128x128 piksel) görüntülerle çalışan modellerin doğruluk oranını %85'in üzerine çıkarmak ve verimli veri artırma teknikleri ile sınırlı veri seti ile eğitim sürecini başarıyla tamamlamaktır.
- 4. Yeni yöntemlerle endüstriyel ortamlarda kalite kontrol süreçlerini iyileştirmektir.**
Araştırma, geliştireceği hibrit model ile endüstriyel ortamlarda (örn. üretim bantları) yağ tohumlarının daha hızlı ve doğru bir şekilde sınıflandırılmasını sağlamayı ve bu sayede işleme sürecini iyileştirmeyi hedeflemektedir. Geliştirilen hibrit modelin endüstriyel ortamlarda test edilmesi ve kalite kontrol sürecinde sınıflandırma doğruluğunu %90'a kadar iyileştirmektir.
- 5. Literatürdeki eksiklikleri gidermek ve yenilikçi bir katkı sunmaktır.**
Literatürde derin öğrenme ve makine öğrenmesi yöntemlerinin yağ tohumu sınıflandırmasındaki etkinliği hakkında sınırlı sayıda çalışma bulunmaktadır. Bu araştırma, mevcut literatüre önemli bir katkı sağlayarak, çeşitli derin öğrenme ve makine öğrenmesi algoritmalarının karşılaştırılmasıyla tohum sınıflandırmasında daha yüksek doğruluk oranları elde edilmesini hedeflemektedir. Derin öğrenme ve makine öğrenmesi yöntemlerinin yağ tohumu sınıflandırması üzerindeki etkisini karşılaştırarak, literatüre yeni akademik makale katkısı sağlamaktır.
- 6. Hibrit yöntemler oluşturarak modellerin performansını artırmaktır.**
Proje, model performansını artırmak için hibrit derin öğrenme ve makine öğrenmesi yöntemlerinin kullanılmasını sağlayacak, böylece yağ tohumlarının sınıflandırılması için daha sağlam ve etkili bir çözüm geliştirecektir. Bu hibrit yaklaşım, mevcut görüntüleme tekniklerinin sınırlarını aşarak daha doğru ve hızlı bir sınıflandırma yapmayı mümkün kılacaktır. Hibrit derin öğrenme ve makine öğrenmesi

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

yöntemlerinin doğruluk oranını %90'ın üzerine çıkarmak ve işlem sürelerini %30 oranında kısaltmaktır.


Araştırmada, teorik olarak tarımsal görüntü işleme alanında hibrit bir yaklaşım sunacak, aynı zamanda metodolojik açıdan derin öğrenme ve makine öğrenmesi tekniklerinin entegrasyonu ile daha verimli ve güvenilir bir çözüm geliştirmeyi amaçlayacaktır. Bu proje yağ tohumlarının otomatik sınıflandırılmasına yönelik önemli bir adım atılmasına olanak sağlayacak ve endüstriyel/tarımsal uygulamalara yenilikçi katkılar sunacaktır.

2. YÖNTEM

Araştırmada uygulanacak yöntem ve araştırma tekniklerinin, amaç ve hedeflere ulaşmaya ne düzeyde elverişli olduğu ilgili literatüre atıf yapılarak ortaya konulur.

Yöntem bölümünün; araştırma tasarımı, bağımlı ve bağımsız değişkenler, istatistiksel yöntemler vb. unsurları içermesi gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin çalışma takvimi ile ilişkilendirilmesi gerekir.

Bu projede, yenilebilir yağ tohumları tespiti için derin öğrenme ve makine öğrenmesi modelleri kullanılacak, veriler ön işleme ve veri artırımı tekniklerine tabi tutulacaktır. Ayrıca, modelin performansı K-katlı çapraz doğrulama yöntemi ile değerlendirilecek ve çeşitli metrikler aracılığıyla doğruluk, hassasiyet ve diğer performans kriterleri analiz edilecektir. Projenin genel çalışma yapısı Şekil 1'de verilmiştir.





Şekil 1. Projenin Genel Çalışma Yapısı

2.1 Yenilebilir Yağ Tohumu Veri Seti

Yenilebilir yağ tohumu veri seti, yaygın olarak yetiştirilen altı yağ tohumu türüne ait 10.111 görüntü içeren veri setini elde etmişlerdir. Bu görüntüleri içeren veri seti, Kaggle platformu üzerinden (yazarlar tarafından) alınmıştır. Görüntüler, iki farklı mobil kamera kullanılarak dijitalleştirilmiştir. Android işletim sistemine sahip bir akıllı telefon (Xiaomi Redmi 10C - 50 MP sensör) ve Android işletim sistemine sahip ikincil bir akıllı telefon (Xiaomi Redmi Note 7S - 48 MP sensör) kullanılmıştır. Daha sonra, yazarlar, görüntüleri altı tohum türüne göre etiketleyerek ve (yeniden boyutlandırma, normalleştirme) ön işleyerek hazırlamışlardır. Veri seti için kategoriler Tablo 2'de verilmiştir (Chordiya vd., 2024). Bu çalışmada kullanılacak veriler kamuya açılmış ve kaynak gösterilmesi halinde kullanımına izin verilmiş verilerdir. Etik izne ihtiyaç yoktur. Chordiya vd. (2024)

Tablo 2. Veri setindeki yenilebilir yağ tohumları örnekleri

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Siyah Susam Tohumu	Hardal Tohumu	Soya Fasulyesi Tohumu	Ayçiçek Tohumu	Beyaz Susam Tohumu	Yer Fıstığı Tohumu
					

2.2 Python Platformu ve Kodlama

Bu projede, yağ tohumlarının sınıflandırılması için derin öğrenme ve makine öğrenmesi modelleri geliştirilirken Python platformu kullanılacaktır. Python, güçlü kütüphaneleri ve geniş topluluk desteği sayesinde derin öğrenme ve makine öğrenmesi projelerinde tercih edilen bir programlama dilidir. Proje kapsamında Python'un sunduğu çeşitli kütüphaneler, veri işleme, model eğitimi ve değerlendirilmesi süreçlerinde aktif olarak kullanılacaktır (Sharma vd., 2023).

İlk aşamada, Python'daki NumPy ve Pandas gibi kütüphanelerle veri ön işleme işlemleri yapılacaktır. Görüntülerin boyutları, çözünürlükleri ve renk kanalları gibi özellikler düzenlenecek, veri setindeki eksik değerler ve gürültüler giderilecektir. OpenCV ve Pillow gibi kütüphaneler, görüntü işleme süreçlerini kolaylaştıracaktır. Ayrıca, veri artırımı için TensorFlow ve Keras'ın sunduğu fonksiyonlar kullanılacak, modelin genelleme yeteneği artırılacaktır.

Derin öğrenme modellerinin eğitim sürecinde, Python ekosisteminin temel taşları olan TensorFlow ve Keras kütüphaneleri kullanılacaktır. Bu kütüphaneler, VGG16 ve InceptionV3 gibi mimarilerin inşasını ve eğitimini kolaylaştıran gelişmiş araçlar sunmaktadır. Eş zamanlı olarak, k-en yakın komşu ve destek vektör makineleri gibi geleneksel makine öğrenmesi algoritmalarının eğitimi Scikit-learn kütüphanesi aracılığıyla gerçekleştirilecektir. Python'un sağladığı esnek altyapı, bu farklı disiplinlere ait modellerin hibrit bir çatı altında teknik entegrasyonunu mümkün kılmaktadır (Jha vd., 2019).

Modelin doğruluğunu artırmak için Python'da K-katlı çapraz doğrulama tekniği uygulanacaktır. Scikit-learn kütüphanesi, çapraz doğrulama ve model değerlendirme metrikleri için gerekli araçları sağlayacaktır. Python'da Matplotlib ve Seaborn gibi görselleştirme kütüphaneleriyle, modelin performansı görsel olarak sunulacak ve sonuçlar analiz edilecektir.

Projede geliştirilecek derin öğrenme ve makine öğrenmesi modelleri, Python ile uyumlu API'ler aracılığıyla endüstriyel ortamlara entegre edilebilecektir. Python'un Flask ve FastAPI gibi web framework'leri, modelin endüstriyel sistemlerle entegrasyonunu sağlayacak ve uygulamanın verimli bir şekilde çalışmasına olanak tanıyacaktır. Python'un sağladığı esneklik ve geniş kütüphane desteği, projenin her aşamasında etkili ve verimli bir çözüm sunacaktır.

2.3 Verilerin Ön İşleme Tabi Tutulması ve Veri Artırımı

Bu projede kullanılan yenilebilir yağ tohumu veri seti, iki farklı mobil kamera (mobil görüntüleme sistemi) ile dijitalleştirme yöntemleriyle elde edilen ve yazarlar tarafından etiketlenmiş görüntülerden oluşmaktadır. İlk aşama olarak, bu görüntüler üzerinde veri ön işleme yapılacaktır. Bu süreç, görüntülerin modeller için uygun hale getirilmesi gerekmektedir. Görüntüler, çeşitli çözünürlüklerde ve boyutlarda olabileceği için, görüntüler tek bir boyuta ve çözünürlüğe normalize edilecektir. Bu, tüm görüntülerin (örn. 224x224 piksel) aynı boyutta olmasını sağlayarak modelin daha hızlı ve doğru eğitim sağlamasına yarayacaktır (Kamilaris & S. A. M., 2021)

Görüntü kirliliği (gürültü), özellikle farklı mobil kameralar kullanılarak çekilen fotoğraflarda yaygın bir sorundur. Bu tür kirlilikler, görüntüde istenmeyen gürültü, bulanıklık ve düşük kontrast gibi sorunlara yol açmaktadır. Bu sebeple, verilerin daha temiz ve net hale gelmesi için görüntü temizleme (filtreleme) işlemi uygulanacaktır. Gürültü giderme teknikleri ve filtreleme yöntemleri kullanılarak, verilerin kalitesi artırılacak ve modelin performansı iyileştirilecektir (Shorten ve Khoshgoftaar, 2019).

Veri artırımı, eğitim verisinin çeşitliliğini artırarak modelin genelleme yeteneğini güçlendirir. Bu proje kapsamında, veri artırımı için çevirme, döndürme, yakınlaştırma, parlaklık/kontrast ayarı ve yatay/dikey kaydırma gibi işlemler uygulanacaktır. Bu sayede, eğitim veri seti genişletilecek ve modelin farklı görüntüleme koşullarına karşı daha dayanıklı olması sağlanacaktır. Veri artırımı işlemleri sırasında görüntülerin farklı ışık koşullarında, farklı açılardan ve çözünürlüklerde tekrar üretilmesi sağlanarak modelin her türlü koşulda yağ tohumlarını sınıflandırma başarısı artırılacaktır. Bu tür bir çeşitlendirme, özellikle endüstriyel ortamlarda veya farklı cihazlarla çekilmiş görüntülerdeki performans farklarını minimize edecektir. (Gnyawali vd., 2022)

Bu veri ön işleme aşamaları, yağ tohumlarının doğru ve hızlı bir şekilde sınıflandırılmasını sağlamak için yapılacaktır.

2.4 Derin Öğrenme Modelleri

Makine öğrenmesinin özelleşmiş bir alt disiplini olan derin öğrenme, büyük veri kümeleri üzerinde karmaşık örüntüleri tanımlama ve genelleme yapabilme kapasitesiyle öne çıkmaktadır. Temelini, biyolojik sinir sisteminin çalışma prensiplerinden esinlenen yapay sinir ağları (YSA) oluşturur. Çok katmanlı hiyerarşik bir mimariye sahip olan bu ağlarda, her bir katman önceki katmandan gelen veriyi işleyerek daha soyut ve karmaşık özelliklerin çıkarılmasını sağlar. Bu katmanlı yapı, verinin derinliklerinde yatan gizli ilişkilerin ve desenlerin manuel müdahaleye gerek kalmadan, otomatik olarak öğrenilmesini mümkün kılar (Jha vd., 2019; Kamilaris & Prenafeta-Boldú, 2018).

Derin öğrenme modelleri, özellikle büyük ve karmaşık veri setlerinden (örneğin, görüntüler, sesler, metinler) anlamlı bilgiler çıkarma yetenekleri ile tanınır. Bu özellik, özellikle görüntü işleme, doğal dil işleme ve zaman serisi analizleri gibi alanlarda devrim yaratmıştır. Görüntü işleme alanında, derin öğrenme yöntemleri, nesne tanıma, segmentasyon ve sınıflandırma gibi görevlerde son derece başarılı sonuçlar elde etmektedir. Tarımsal görüntü işleme ise derin öğrenmenin en etkili kullanıldığı alanlardan biridir, çünkü tarımsal veriler genellikle çok büyük ve karmaşık olup, bu verilerdeki ince detayların doğru bir şekilde analiz edilmesi gerekmektedir (Kamilaris & Prenafeta-Boldú, 2018; Sharma vd., 2023).

Yağ tohumu sınıflandırması, özellikle tarım ve gıda endüstrisinde önemli bir görüntüleme ve kalite kontrol sürecidir. Yağ tohumları, farklı türler veya kaliteler içerir ve bu tohumlar, çoğu zaman dijital görüntülerde fark edilmeden önce belirgin morfolojik benzerlikler gösterir. Bu, tarımsal görüntülerin analizi için doğru, hızlı ve hassas bir yaklaşımın gerekliliğini ortaya koymaktadır. Yağ tohumları genellikle küçük boyutlarda ve incelikli ayrıntılarla (doku, renk farkları) sınıflandırılır, bu da geleneksel yöntemlerle tespitlerini zorlaştırır. Derin öğrenme, bu alandaki en önemli yeniliklerden biri olarak, görüntülerdeki ince detayları öğrenme ve doğru bir şekilde sınıflandırma yeteneği ile öne çıkar (Zhang vd., 2023).

Derin öğrenme algoritmalarının avantajları, özellikle görüntülerdeki desenleri otomatik olarak öğrenme ve genelleme yeteneklerinde yatmaktadır. Geleneksel makine öğrenme tekniklerinin çoğu, elle seçilen özelliklere (morfolojik özellikler vb.) dayanırken, derin öğrenme, özellik çıkarımı (feature extraction) aşamasını otomatikleştirir. Bu, modelin veriye dayalı olarak daha doğru ve derin özellikler öğrenmesini sağlar. Örneğin, yağ tohumu sınıflandırmasında kullanılan derin öğrenme yöntemleri, yalnızca tohumun türünü (sınıfını) belirlemekle kalmaz, aynı zamanda kalitesini, boyutunu ve diğer özelliklerini de doğru şekilde sınıflandırabilir. Ayrıca, bu yöntemler büyük veri setleri ile eğitildiklerinde, model zamanla daha doğru ve güvenilir sonuçlar üretir (Pasha vd., 2022; Ahmad vd., 2023).

Derin öğrenme sistemleri görüntülerdeki yerel özellikleri öğrenmek için evrişim katmanlarını (convolutional layers) kullanarak, görsel verilerdeki detayları anlamada son derece etkili olur. Bu özellikleri, tarımsal görüntülerdeki küçük (morfolojik) farkları tespit etme sürecinde büyük avantaj sağlar. Özellikle tarımsal görüntüleme alanında derin öğrenmenin kullanımı, yalnızca görüntüleri sınıflandırmakla kalmaz, aynı zamanda kalite kontrolü, otomasyon, verimli ayıklama ve üretim izlemeleri için büyük bir potansiyel taşımaktadır (Kamilaris & Prenafeta-Boldú, 2018).

Derin öğrenme, tarımsal görüntü işleme ve özellikle yağ tohumu sınıflandırmasında büyük bir potansiyele sahiptir. Derin öğrenme modelleri, yalnızca yüksek doğrulukla tohumları sınıflandırmakla kalmaz, aynı zamanda bu tohumların özelliklerini tanıyıp sınıflandırarak endüstriyel otomasyon sistemlerine daha iyi bir karar destek sistemi sunar. Bu teknolojinin gelişmesiyle birlikte, tarım ve gıda sektöründe daha doğru ve hızlı kalite kontrol süreçleri mümkün hale gelmektedir.

Bu araştırmada, yağ tohumlarının sınıflandırılması için üç farklı derin öğrenme modeli kullanılacaktır: VGG16, InceptionV3 ve SqueezeNet. Aşağıda her bir modelin özellikleri sırasıyla açıklanmıştır.

2.4.1 VGG16

Oxford Üniversitesi Visual Geometry Group (VGG) tarafından 2014 yılında literatüre kazandırılan VGG16, özellikle görüntü sınıflandırma görevlerindeki yüksek başarımıyla tanınan bir derin öğrenme mimarisidir. Modelin temel yapısı, on üçü evrişim (convolutional) ve üçü tam bağlantılı (fully connected) olmak üzere toplam 16 ağırlık katmanından meydana gelir. Bu derin mimari, görüntülerdeki karmaşık nesne ve detayların hassasiyetle analiz edilmesine olanak tanır. Modelin ayırt edici özelliklerinden biri, özellik çıkarımı sürecinde 3x3 boyutunda küçük filtrelerin kullanılmasıdır. Ayrıca, sistemin hesaplama verimliliğini artırmak ve işlem yükünü optimize etmek amacıyla, her evrişim katmanını takiben ReLU aktivasyon fonksiyonları ve Max Pooling katmanları entegre edilmiştir (Tammina, 2019; Sitaula ve Hossain, 2021; Verma, 2022).

Modelin derin yapısı ve yaklaşık 138 milyon parametre içermesi, VGG16'yı hesaplama açısından yoğun ve yüksek bellek gerektiren bir model haline getirir. Bu nedenle, büyük veri setleri üzerinde eğitim yapılması için güçlü

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

ARAŞTIRMA ÖNERİSİ FORMU

GPU'lar gereklidir. Ancak, bu hesaplama maliyetine rağmen, model çeşitli görüntü işleme görevlerinde, özellikle tarımsal görüntü analizi ve yüksek doğruluk gerektiren kalite kontrol uygulamalarında oldukça başarılı sonuçlar sunar. VGG16, transfer öğrenme için de uygun bir yapı sunar ve bu sayede farklı veri setleriyle hızlıca eğitilip uygulanabilir (Tammina; 2019; Sitaula ve Hossain, 2021).

VGG16'nın avantajları arasında yüksek doğruluk ve basit, düzenli bir mimari yapısı bulunur. Derin yapısı sayesinde detaylı özellik çıkarımı yaparak yüksek doğruluk sağlar. Bununla birlikte, yüksek hesaplama maliyeti ve büyük veri gereksinimi, modelin dezavantajları arasında sayılabilir. Modern modellerle kıyaslandığında daha yavaş çalışabilse de, gıda kalite kontrolü gibi yüksek doğruluk gerektiren alanlarda yaygın olarak tercih edilir (Pandiar vd., 2023; Shah vd., 2023).

2.4.2 InceptionV3

InceptionV3, Google tarafından geliştirilen ve daha karmaşık bir mimariye sahip olan bir derin öğrenme modelidir. 2015 yılında tanıtılan bu model, özellikle görsel tanıma ve sınıflandırma görevlerinde yüksek performans gösterir. InceptionV3, 48 katmandan oluşur ve Inception modülleri kullanarak farklı boyutlardaki filtreleri paralel olarak işlemesine olanak tanır. Bu modüller, modelin farklı özellikleri aynı katmanda paralel bir şekilde çıkarmasına imkân verir. Bu esneklik, modelin daha geniş bir özellik kümesi üzerinde çalışmasına olanak tanır ve daha verimli sonuçlar elde edilmesini sağlar (Ramaneswaran vd., 2021; Sam vd., 2019).

InceptionV3 modelinin ayırt edici özelliği, farklı boyutlardaki filtreleri paralel bir mimariye işleyebilmesidir. Bu yapısal esneklik, modelin işlem yükünü minimize ederken aynı zamanda bilgi çıkarım kapasitesini artırmaktadır. Parametre sayısının optimize edilmesi sayesinde, model hem öğrenme sürecini hızlandırmakta hem de hesaplama gücü gereksinimini düşürmektedir. Sonuç olarak, büyük ölçekli veri setlerinde dahi performans kaybı yaşanmadan, hesaplama verimliliği yüksek ve hızlı sonuçlar elde edilebilmektedir (Sam vd., 2019; Ramaneswaran vd., 2021).

Yağ tohumu sınıflandırması gibi tarımsal görüntüleme projelerinde, InceptionV3 modeli geniş özellik çıkarma kapasitesiyle önemli bir avantaj sunmaktadır. Modelin sahip olduğu yüksek performans ve verimlilik dengesi, onu birçok farklı uygulama alanı için ideal bir seçenek haline getirir. Büyük veri kümelerinde üstün genelleme yeteneği sergilemesi ve hızlı çalışma prensibi, uygulamalarda ciddi oranda zaman tasarrufu sağlar. Bu nitelikler, hızlı ve hassas kalite kontrolü gerektiren süreçlerde modelin sıklıkla tercih edilmesinin temel nedenidir (Pandiar vd., 2023; Shah vd., 2023).

2.4.3 SqueezeNet

Özellikle sınırlı işlem gücüne sahip cihazlar için optimize edilen SqueezeNet, hafif ve verimli yapısıyla öne çıkan bir derin öğrenme modelidir. Model, bünyesindeki 'Fire' modülleri sayesinde parametre yoğunluğunu düşürürken etkili özellik çıkarımı yapabilmektedir. Birbiri ardına gelen 'sıkıştırma' (squeeze) ve 'genişletme' (expand) katmanlarını içeren bu modüller, işlem yükünü azaltarak bilgi akışını düzenler. Sonuç olarak, 2016 yılından bu yana kullanılan bu model, düşük donanım kaynağı tüketen projelerde ve mobil uygulamalarda yüksek performanslı bir çözüm sunmaktadır (Elhassouny ve Smarandache; 2019; Tulasi vd., 2021).

SqueezeNet'in hafif yapısı, düşük bellek ve işlem gücü gereksinimi ile çalışabilmesini sağlar, bu da mobil cihazlar ve kaynakları sınırlı sistemler için büyük bir avantajdır. Model, daha az parametre ile verimli bir şekilde çalışarak özellikle mobil uygulamalar ve gerçek zamanlı işlem gerektiren projelerde kullanışlıdır. Bununla birlikte, SqueezeNet daha düşük doğruluk performansına sahip olabilir çünkü modelin yapısı daha sadeleştirilmiştir, ancak bu durum işlem gücünden büyük tasarruf sağlar (Elhassouny ve Smarandache; 2019; Tulasi vd., 2021).

SqueezeNet'in avantajları, hafifliği ve verimliliğidir. Özellikle mobil cihazlar veya sınırlı kaynaklarla çalışan sistemlerde tercih edilir. Ayrıca, tarımsal uygulamalar gibi alanlarda da kullanılabilir; ancak doğruluk açısından daha büyük, daha derin modellere kıyasla sınırlı kalabilir. Yine de, işlem gücünden tasarruf sağlamak isteyen uygulamalar için güçlü bir seçenek sunar ve düşük kaynak gereksinimi ile hızlı ve etkili sonuçlar elde edilmesini sağlar (Pandiar vd., 2023; Shah vd., 2023).

2.4.4 Kullanılacak Derin Öğrenme Modellerinin Karşılaştırılması

Yağ tohumlarının sınıflandırılması gibi endüstriyel görüntü sınıflandırma işlemlerinde literatürde sıklıkla VGG16, InceptionV3 ve SqueezeNet olmak üzere üç farklı derin öğrenme modelleri kullanılmaktadır. Bu derin öğrenme tabanlı görüntü sınıflandırma modellerinin her birinin kendine özgü mimari özellikleri (parametrik karmaşıklık, katman derinliği ve işlem hızı) bulunmaktadır. Bu modellerin genel özellikleri ve birbirleriyle kıyaslanarak Tablo 3'te verilmiştir.

Model	Genel Özellikleri
VGG16	On üçü evrişim (convolutional) ve üçü tam bağlantılı (fully connected) olmak üzere toplam 16 ağırlık katmanından oluşan VGG16 mimarisi, derin yapısıyla karakterize edilmektedir. Bu model, görüntü üzerindeki mekansal hiyerarşileri ve karmaşık öznitelikleri yakalamak

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

	amacıyla, ardışık olarak uygulanan 3x3 boyutundaki küçük filtreler (kernels) kullanmaktadır. Söz konusu derin mimari, tohum görüntülerinden zengin bilgi özelliklerinin çıkarılmasına olanak tanımakla birlikte, içerdiği yüksek parametre sayısı nedeniyle önemli bir hesaplama maliyeti ve bellek gereksinimi doğurmaktadır. Buna karşın, modelin sunduğu üstün doğruluk oranı, tıbbi görüntüleme hassas endüstriyel kalite kontrol uygulamalarına kadar birçok alanda referans model olarak kullanılmasını sağlamaktadır.
InceptionV3	Toplam 48 katmanlı bir derinliğe sahip olan InceptionV3, temel yapı taşı olarak özelleştirilmiş Inception modüllerini kullanmaktadır. Bu modüller, farklı boyutlardaki filtreleri paralel bir düzende çalıştırarak, aynı katman içerisinde hem ince detayların hem de genel morfolojik özelliklerin eş zamanlı olarak çıkarılmasını (multi-scale feature extraction) mümkün kılmaktadır. Bu mimari yaklaşım, hesaplama karmaşıklığını optimize ederken geniş bir özellik kümesinin elde edilmesini sağlamakta; böylece modelin hesaplama verimliliği ile yüksek sınıflandırma performansı arasında dengeli bir çözüm sunmasına olanak tanımaktadır.
SqueezeNet	Sınırlı donanım kaynaklarında çalışmak üzere tasarlanan SqueezeNet, katman sayısını minimize eden ve Fire modülleri olarak adlandırılan özel bloklar kullanan hafif (lightweight) bir mimariye sahiptir. Bu modüller, parametre sayısını radikal biçimde düşürmek için "sıkıştırma" (squeeze) ve "genişletme" (expand) stratejilerini kullanır. Modelin bu kompakt yapısı, sınıflandırma doğruluğundan ödün vermeden düşük işlem gücü gerektirmesini sağlar. Bu özellikleri sayesinde SqueezeNet, mobil cihazlar, gömülü sistemler ve gerçek zamanlı endüstriyel el terminaleri gibi sınırlı kaynaklara sahip ortamlarda verimli bir şekilde uygulanabilmektedir.

2.5 Makine Öğrenmesi Modelleri
Yağ tohumlarının sınıflandırılması için literatürde sıklıkla kullanılan makine öğrenme algoritmalarından yapay sinir ağları, k-en yakın komşu, destek vektör makineleri, random forest ve gradient boosting algoritmaları, her birinin özellikleri ve kullanım amacı sırasıyla açıklanmıştır.

2.5.1 Random Forest (RF)

Temel çalışma prensibi çok sayıda karar ağacından gelen sonuçların birleştirilmesine dayanan Random Forest, etkili bir makine öğrenmesi algoritmasıdır. Her bir ağacın tahminini dikkate alarak çoğunluk oylaması ile sonuç üreten bu topluluk yöntemi (ensemble method), hem sınıflandırma hem de regresyon görevlerinde kararlı sonuçlar üretir. Finans ve pazarlama gibi sektörlerin ötesinde, tarımsal otomasyon süreçlerinde de sıklıkla tercih edilmektedir. Bu bağlamda, yağ tohumlarının dijital görüntüleri üzerinden tür tespiti yapılması veya kalite kusurlarının belirlenmesi gibi endüstriyel süreçlerde, Random Forest algoritması üreticiler için hızlı ve doğru analiz imkânı sağlamaktadır (Jun, 2021; Ramdani ve Furqon, 2022).

Random Forest'in temel çalışma prensibi, veri setinin farklı alt kümelerinden rastgele örnekler seçerek birçok karar ağacı oluşturmaktır. Her bir karar ağacı, bağımsız olarak bir tahmin yapar ve tüm ağaçların verdiği sonuçların çoğunluğuna göre nihai tahmin belirlenir. Bu topluluk yöntemi, tek bir karar ağacının verebileceği hataları azaltmakta ve yüksek doğruluk oranları sağlamaktadır. Ayrıca Random Forest algoritması aşırı öğrenmeye (overfitting) karşı dayanıklı olmasıyla da bilinmektedir; bu özellik, algoritmanın daha önce görülmemiş verilere genelleme yapma yeteneğini artırmaktadır. Tarımsal kalite kontrolü ve gıda endüstrisi gibi alanlarda, Random Forest algoritması ile tohum verileri sınıflandırılmakta, görüntüler analiz edilmekte, kalite riskleri tahmin edilmekte ve endüstriyel karar süreçleri desteklenmektedir (Chumachenko vd., 2022; Jun, 2021).

2.5.2 K-en Yakın Komşu (KNN)

Veri madenciliği ve örüntü tanıma alanlarında, sadeliği ve sınıflandırma başarıyla öne çıkan K-en Yakın Komşu (k-NN) algoritması, tarımsal ürünlerin otomatik tasnifinde sıklıkla başvurulmuş parametrik olmayan bir yöntemdir. Algoritma, yeni bir veri örneğini sınıflandırmak için, öznitelik uzayında o örneğe en yakın komşuların çoğunluk kararına dayanır. Özellikle tarımsal kalite kontrol süreçlerinde; tohumların tür tespiti, yabancı maddelerin ayıklanması ve fiziksel kusurların belirlenmesi gibi görevlerde k-NN algoritması yüksek doğruluk oranları sunmaktadır. Bu bağlamda, fasulye veya kabak çekirdeği gibi morfolojik çeşitliliğin yüksek olduğu ürünlerde, k-NN tabanlı sistemler endüstriyel ayıklama süreçlerinin otomasyonuna önemli katkılar sağlar (Koklu ve Ozkan, 2020; Koklu vd., 2021).

Algoritmanın çalışma prensibi, sınıfı bilinmeyen bir tohum örneğinin, veri setindeki diğer örneklerle olan uzaklığının hesaplanmasına dayanır. Genellikle Öklid (Euclidean) veya Manhattan gibi uzaklık metrikleri kullanılarak yapılan bu hesaplamada, "k" (komşu sayısı) parametresinin seçimi modelin başarısında kritik bir rol oynar. Örneğin, susam tohumlarının sınıflandırıldığı çalışmalarda, doğru "k" değerinin seçilmesiyle (örn. k=3) %97'nin üzerinde başarı elde edilebildiği görülmüştür. Tüm eğitim verisini hafızada tutarak işlem yapılması nedeniyle "tembel öğrenme" (lazy learning) olarak da adlandırılan bu yöntem, tohum verilerinin sınıflandırılması ve benzer kalite gruplarının oluşturulmasında üreticilere/uzmanlara basit ancak güçlü bir karar destek mekanizması sunar (Çelik vd., 2020).

2.5.3 Destek Vektör Makineleri (SVM)

Destek Vektör Makineleri (SVM), sınıflandırma ve regresyon problemlerinde etkili sonuçlar veren bir makine öğrenme algoritmasıdır. SVM, veriyi belirli sınıflara ayırmak için en iyi ayırıcı çizgiyi veya hiper düzlemi bulmayı amaçlar. Sınıflandırma işlemini, farklı sınıfları birbirinden en fazla uzaklıkta tutacak şekilde sınırlar oluşturarak gerçekleştirir. Bu özellikleri sayesinde SVM, tarım, finans, metin madenciliği ve görüntü işleme gibi birçok alanda yaygın olarak kullanılmaktadır. Tarımsal uygulamalarda, kalite kusuru tespiti, görüntü sınıflandırması ve tarımsal verilerin analizinde başarıyla uygulanmaktadır. Gıda endüstrisi alanında da, dijital görüntülerde tohum kusuru veya tür enfeksiyonlarının tespiti için SVM algoritması kullanılabilir; böylece kalite kontrol uzmanları doğru sınıflandırma ve ayıklama süreçlerine daha hızlı ulaşabilirler (Ramdani ve Furqon, 2022; Beskopylny vd., 2022).

SVM'nin temel prensibi, veri noktalarını sınıflara ayıran en iyi hiper düzlemi bulmak ve bu düzleminden uzak olan verilerin doğruluğunu artırmaktır. Destek vektörleri olarak adlandırılan belirli veri noktaları, bu düzlemin oluşturulmasında önemli rol oynar ve sınıflandırma sürecinde yüksek doğruluk sağlar. Ayrıca SVM, doğrusal olmayan veri kümeleri için de çekirdek (kernel) fonksiyonları kullanarak veriyi daha yüksek boyutlu bir uzaya dönüştürme kapasitesine sahiptir. Bu sayede daha karmaşık veri ilişkilerini öğrenebilir ve sınıflandırma doğruluğunu artırabilir. Tarım ve gıda endüstrisi alanlarında, SVM algoritması ürün verilerini sınıflandırmak, dijital görüntüleri analiz etmek, çeşit veya kusur türlerini tanımlamak gibi işlemlerde yüksek başarı oranları sunarak uzmanların karar süreçlerinde güçlü bir destek sağlamaktadır.

2.5.4 Gradient Boosting (GB)

Gradient Boosting, sınıflandırma ve regresyon problemlerinde güçlü tahminler yapan bir makine öğrenme algoritmasıdır. Bu algoritma, zayıf öğrenicilerden (genellikle karar ağaçlarından) oluşan bir model grubunu ardışık olarak birleştirerek tahmin hatalarını aşamalı olarak azaltmayı hedefler. Her bir yeni ağaç, önceki ağaçların yaptığı hataları telafi edecek şekilde eğitilir ve böylece model her adımda daha doğru sonuçlar elde eder. Gradient Boosting, tarım, finans, pazarlama ve öneri sistemleri gibi birçok alanda, yüksek doğruluk oranlarına ulaşması ve esnekliği sayesinde sıklıkla tercih edilmektedir (Natekin ve Knoll, 2013; Chumachenko vd., 2022). Tarımsal kalite kontrol alanında ürün kusuru tespiti, tarımsal verilerin analiz edilmesi ve rekolte sonuçlarının öngörülmesinde başarılı bir performans sergiler (Pandiar vd., 2023). Gıda endüstrisi uygulamalarında ise, örneğin tohum görüntüleri ve analiz verileri yaparak tür tespiti veya diğer kalite sorunlarının tanımlanmasında Gradient Boosting kullanılabilir ve uzmanlara etkili bir sınıflandırma desteği sunar.

Gradient Boosting'in temel prensibi, her bir ağacın önceki modelin hatalarını öğrenmesi ve bu hataları düzelterek modelin genel performansını artırmasıdır. Bu ardışık öğrenme süreci, modelin aşırı öğrenmeden (overfitting) korunmasına da katkıda bulunur. Ayrıca, Gradient Boosting algoritması hata oranını sürekli azaltarak son derece güçlü bir topluluk model oluşturur (Bentéjac vd., 2021). Tarım ve gıda endüstrisi gibi alanlarda Gradient Boosting, dijital görüntüleri analiz etme, ürün risklerini tahmin etme ve tarımsal verileri kategorize etme gibi işlemlerde yüksek doğruluk ve genelleme yeteneği ile değerli sonuçlar sunmakta ve üreticilere/uzmanlara sınıflandırma ve ayıklama süreçlerinde önemli bir destek sağlamaktadır.

2.5.5 Yapay Sinir Ağları (YSA)

Yapay sinir ağları (YSA), insan beynindeki nöronların çalışma biçiminden esinlenmiş bir yapay zeka modelidir. Bu model, büyük miktarda veriyi analiz etme, desenleri tanıma ve veriyi belirli kategorilere ayırma gibi görevlerde etkili bir çözüm sunmaktadır. Özellikle tarım ve gıda endüstrisi alanında, YSA kalite kusurlarının teşhisinde, tarımsal görüntülerin analizinde ve endüstriyel verilerin yorumlanmasında değerli katkılar sağlamaktadır. Örneğin, bir tohum veya ürün görüntüsünde sağlıklı ve kusurlu tohumları ayırmak veya çeşitli tohum türlerini tanımak için kullanılabilir.


Endüstriyel otomasyon sistemleri için de YSA, konveyör bant görüntüleri veya laboratuvar analiz verileri üzerinde analiz yaparak tohum türü tespiti, yabancı madde ayıklama veya diğer kalite kusurlarının tanımlanmasında yardımcı olmaktadır. Bu uygulamalar, üreticilerin daha hızlı ve doğru sınıflandırma koymalarını sağlayarak üretim verimliliğini iyileştirmektedir (Zou vd., 2009; Er vd., 2010).

YSA'nın başarısının temelinde kendi kendini öğrenme ve geliştirme yeteneği yatmaktadır. Öğrenme sürecinde ağırlık her bir bağlantısına "ağırlık" adı verilen değerler atanmakta ve tahminlerin doğruluğunu artırmak için bu ağırlıklar sürekli olarak güncellenmektedir. Bu güncellemeler, geriye yayılım (backpropagation) adı verilen bir algoritma ile yapılır. Geriye yayılım algoritması, her bir tahminin hatasını analiz ederek bağlantılardaki ağırlıkları optimize eder, böylece ağırlık daha doğru sonuçlar üretmesini sağlar. Ayrıca YSA'da kullanılan aktivasyon fonksiyonları, nöronlar arasında doğrusal veya doğrusal olmayan işlemler uygulayarak karmaşık veri ilişkilerini öğrenme kapasitesini artırmaktadır. Bu özellikler, tarım ve gıda endüstrisi alanlarında büyük bir değere sahiptir; görüntü işleme, kalite sınıflandırma ve tarımsal verilerin analizi gibi süreçlerde YSA, yüksek doğruluk oranları ile anlamlı sonuçlar ortaya koymakta, üreticilere ve kalite kontrol uzmanlarına sınıflandırma ve ayıklama süreçlerinde önemli bir destek sağlamaktadır (Al-Shayea., 2011; Er vd., 2010; Zou vd., 2009).

2.6 K-katlı Çapraz Doğrulama (K-fold- Cross-Validation)

Derin öğrenme modellerinin performansını değerlendirmek ve aşırı öğrenme (overfitting) probleminin önüne

geçmek amacıyla K-katlı Çapraz Doğrulama (K-fold Cross-Validation) yöntemi kullanılacaktır. Bu yaklaşım, eldeki verinin tamamının hem eğitim hem de test süreçlerinde etkin bir şekilde kullanılmasını sağlayarak, modelin genelleme yeteneğine dair güvenilir sonuçlar sunar. Süreç, veri setinin K adet eşit parçaya (fold) ayrılmasıyla başlar. Her iterasyonda, parçalardan biri test seti olarak ayrılırken, kalan K-1 parça eğitim seti olarak işlev görür. Bu döngü, her parçanın bir kez test verisi olarak kullanılmasına kadar K kez tekrarlanır. Son aşamada, tüm döngülerden elde edilen başarı metriklerinin ortalaması alınarak modelin nihai performansı hesaplanır. Veri setinin hacmine ve problemin yapısına göre K değeri literatürde genellikle 5 veya 10 olarak tercih edilmektedir (Syed, 2011; Yates vd., 2023). Proje kullanılması planlanan 10-Kat çapraz doğrulama Şekil 2’de verilmiştir.



Şekil 2. 10-Kat çapraz doğrulama

Modelin performans tutarlılığını artırmak amacıyla kullanılan K-katlı çapraz doğrulama, literatürde kabul görmüş kritik avantajlara sahiptir (Jung, 2018; Yates vd., 2023):

Genellenebilirlik: Modelin farklı veri parçaları üzerindeki başarısını test ederek, ezberleme (overfitting) riskini minimize eder ve modelin daha önce görmediği veriler üzerindeki tahmin gücünü doğrular.

Veri Verimliliği: Her veri noktası döngüsel olarak hem eğitim hem de test aşamasında kullanılır. Bu yaklaşım, eldeki veri setinden maksimum verim alınmasını sağlayarak performans analizinin doğruluğunu artırır.

Yanlılığın Azaltılması: Her seferinde farklı bir veri bloğunun test seti olarak ayrılması, modelin sabit bir eğitim kümesine aşırı odaklanmasını engelleyerek yanlılığı (bias) düşürür.

Sonuç Güvenilirliği: Tek bir veri ayrımı (split) kullanmak istatistiksel sapmalara yol açabilirken; K-katlı yapıda tüm katmanların doğruluk ortalamasının alınması, model başarımının daha kararlı ve güvenilir bir şekilde raporlanmasını sağlar.

Model Optimizasyonu: Farklı algoritmaların veya hiperparametre konfigürasyonlarının karşılaştırılmasında etkin bir yöntemdir; en yüksek performansı veren modelin belirlenmesinde belirleyici rol oynar.

2.7 Performans Metrikleri ve Değerlendirilmesi

Sınıflandırma algoritmalarının başarı düzeylerinin nesnel bir zeminde karşılaştırılabilmesi, evrensel kabul görmüş performans metriklerinin kullanılmasına bağlıdır. Model performansının somutlaştırılmasında, tahmin edilen sınıflar ile gerçek etiketler arasındaki eşleşme durumunu sayısal olarak ifade eden hata matrisi (confusion matrix) temel alınır. Bu matris, modelin hangi tohum türlerinde veya sınıflarda karıştırma hatası yaptığını detaylı bir şekilde analiz etmeye olanak tanır. Bu çalışmada geliştirilen modellerin etkinlik analizi, hata matrisi üzerinden türetilen dört ana ölçüt ile gerçekleştirilecektir: Doğruluk (Accuracy), Duyarlılık (Recall), Kesinlik (Precision) ve F1-skoru. Söz konusu metrikler, modelin sınıflandırma güvenilirliğini ve ayırt etme gücünü istatistiksel olarak ortaya koymaktadır (Koklu vd., 2021; Gulzar vd., 2020; Hossin ve Sulaiman, 2015).

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

		Gerçek değerler			
		Pozitif (1)	Negatif (0)		
Tahmin değerleri	Pozitif (1)	TP	FP	TP (True Pozitif)	Hem gerçekte pozitif olan hem de modelin pozitif olarak tahmin ettiği değerlerdir.
	Negatif (0)	FN	TN	TN (True Negatif)	Hem gerçekte negatif olan hem de modelin negatif olarak tahmin ettiği değerlerdir.
				FP (False Pozitif)	Gerçekte negatif olan ama modelin pozitif olarak tahmin ettiği değerlerdir.
				FN (False Negatif)	Gerçekte pozitif olan ama makinenin negatif olarak tahmin ettiği değerlerdir.

Confusion Matrix
(Karmaşıklık Matrisi)

Performans Metriklerin hesaplama formülleri

Metrik	Formül
Doğruluk (Accuracy)	$\frac{tp + tn}{tp + fp + tn + fn}$
Hassasiyet (Recall) (r)	$\frac{tp}{tp + fn}$
Kesinlik (Precision) (p)	$\frac{tp}{tp + fp}$
F1 (Skor) (F1-Score)	$\frac{2 * p * r}{p + r} = \frac{2 * \frac{tp}{tp + fp} * \frac{tp}{tp + tn}}{\frac{tp}{tp + fp} + \frac{tp}{tp + tn}}$

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

3. PROJE YÖNETİMİ

3.1 Çalışma Takvimi

Araştırmada yer alacak başlıca faaliyetler, her bir faaliyetin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmacının başarısına katkısı "Çalışma Takvimi" doldurularak sunulur.

ÇALIŞMA TAKVİMİ (*)

Tarih Aralığı	Faaliyetler**	Kim(ler) Tarafından Gerçekleştirileceği	Başarı Ölçütü ve Araştırmacının Başarısına Katkısı***
01 /01 /2026- 01 /03 /2026	Verilerin Elde Edilmesi ve Ön İşlemden Geçirilmesi	Mahmut Esat Kolay, Doç.Dr. Murat Köklü	Başarı Ölçütü: *Veri toplama sürecinin tamamlanması. *Verilerin etiketlenmesi ve uygun formatta ön işleme tabi tutulması. Projenin Başarısına Katkısı: *Doğru veri toplanması projenin amaçlarına ulaşabilmesi ve sağlam temeller üzerine modellerin oluşturulabilmesi için önem arz etmektedir. *Analiz sürecinde kullanılabilirliği artırarak sonuçların güvenilirliğini sağlayacaktır. Katkı oranı: %30
01 /03 /2026- 01 /08 /2026	Veri Setinin Derin Öğrenme Yöntemleriyle Kodlanması ve Test Aşaması	Mahmut Esat Kolay, Doç.Dr. Murat Köklü	Başarı Ölçütü: Derin öğrenme modellerinin kodlanması. Projenin Başarısına Katkısı: Test aşaması, projenin ana hedefinin gerçekleştirilmesine yardımcı olacaktır. Katkı oranı: %35
01 /08 /2026- 01 /09 /2026	Sonuçların Değerlendirilmesi	Mahmut Esat Kolay, Doç.Dr. Murat Köklü	Başarı Ölçütü: Elde edilen sonuçların detaylı analizi ve değerlendirilmesi. Projenin Başarısına Katkısı: Sonuçların analizi, projenin genel başarısını ve gelecekteki çalışmalara yönelik çıkarımları belirleyecektir. Katkı oranı: %25
01 /09 /2026- 01 /10 /2026	Geri Bildirim ve İyileştirme, Raporlaştırma	Mahmut Esat Kolay, Doç.Dr. Murat Köklü	Başarı Ölçütü: Geri bildirimlerin toplanması ve iyileştirme önerilerinin değerlendirilmesi. Projenin Başarısına Katkısı: Geri bildirimler, süreçlerin iyileştirilmesine ve paydaş memnuniyetinin artırılmasına katkı sağlayacaktır. Katkı oranı: %10

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

(**) Literatür taraması, sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı, ve malzeme alımı ayrı birer iş adımı olarak gösterilmemelidir.

(***) Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir. Bu sütundaki değerlerin toplamı 100 olmalıdır.

3.2 Risk Yönetimi

Araştırmacının başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmacının başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) aşağıdaki Risk Yönetimi Tablosu'nda ifade

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

edilir. B Plan(lar)ının uygulanması araştırmacının temel hedeflerinden sapmaya yol açmamalıdır. B Plan(lar)ına geçilmesi durumunda yöntem değişikliğine gidiliyor ise bu durum detaylandırılmalıdır.

RİSK YÖNETİMİ TABLOSU*

En Önemli Riskler	Alınacak Tedbirler (B Planı)
Modelin eğitimi için yeterli sayıda veri elde edilememesi	Kamuya açık veri toplanması veya sentetik veri tabanları üzerinde çalışılması
Modellerin eğitimi için kullanılan verilerin hatalı bir şekilde ön işlem uygulanması	Veriler yeniden ön işleminden geçirilerek tekrar hazırlanması.
Derin öğrenme yöntemler kullanılarak başarılı sonuçlar elde edilememesi	Kullanılan veri setinin farklı bir model kullanılması veya hibrit yeni yöntemlerin denenmesi
Projede bazı iş paketlerinin planlanandan daha uzun sürmesi	Proje süresini yönetmek için düzenli olarak zaman çizelgelerinin kontrol edilmesi ve ihtiyaç halinde iki iş paketinin aynı anda yürütülmesi

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.3.Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	Projede Kullanım Amacı
Selçuk Üniversitesi - Teknoloji Fakültesi Kütüphane	Proje hakkında literatürün taranması, yayınların incelenmesi
Selçuk Üniversitesi - Teknoloji Fakültesi	Proje geliştirilirken ihtiyaç duyulan platformların yüklenmesi, aktif internet bağlantılarının sağlanması, derin öğrenme yöntemlerinin model eğitimi gerçekleştirecek cihazın konumlandırılması vb.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Araştırma önerisi kapsamındaki çalışmadan elde edilmesi öngörülen çıktılar amaçlarına göre belirlenen kategorilere ayrılarak belirtilir; ölçülebilir ve gerçekçi hedeflere dayandırılır.

Çıktı, Etki ve Kazanımlar	Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)
Bilimsel/Akademik Çıktılar (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.)	* 1 adet SCI-E veya TR-Dizin kapsamında taranan dergilerde yayın yapılması hedeflenmektedir. * 1 adet Uluslararası konferansta bildiri sunulması hedeflenmektedir.
Ekonomik/Ticari/Sosyal Çıktılar (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb.)	*Proje, yağ tohumlarının hızlı ve doğru sınıflandırmasını sağlayan bir yazılım prototipi geliştirmeyi amaçlamaktadır. Bu yazılım, tarım ve gıda endüstrisi alanında önemli bir kalite kontrol aracı olarak kullanılabilecek ve endüstriyel otomasyon sektöründe inovatif bir çözüm sunacaktır. * Geliştirilecek yazılım, tarımsal görüntüleme ve kalite güvencesi alanında endüstriyel otomasyon ürünleri kategorisinde tescil edilerek, üretim ve ticaret için yasal

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

	onay alabilir. Ayrıca, gıda ve tarım alanındaki çeşitli uluslararası kalite standartları ve sertifikasyon süreçlerinden geçerek ticari hale getirilebilir. * Proje sonuçları, derin öğrenme ve makine öğrenmesi alanlarında çalıştaylar ve eğitim programları düzenlenmesine olanak tanıyabilir. Bu etkinlikler, hem araştırmacılara hem de üretim mühendislerine ve kalite kontrol uzmanlarına yeni teknolojileri tanıtmak için bir fırsat sağlayacaktır. * Proje, tohum işleme tesisleri, büyük ölçekli gıda üretim firmaları, tarımsal analiz laboratuvarları ve üniversiteler gibi kurumlar tarafından kullanılabilir. Ayrıca, tarım ve gıda sektörü için özel otomasyon ve yazılım sağlayıcıları ile teknoloji firmaları da projeden faydalanabilir.
Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar (Ulusal/Uluslararası Yeni Proje vb.)	* Ulusal veya Uluslararası alanda derin öğrenme yöntemlerini kullanacak yeni projelere ön ayak olması için proje detaylarının paylaşılması planlanmaktadır. * Yüksek Lisans öğrencileri bu veri seti ile yeni projeler ve yayınlar yapabilecektir.

5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

6. EKLER

EK-1: KAYNAKLAR

Ahad, T., vd. (2023). A Hybrid Neural Network from VGG with MobileNet to Extract Features and Classification by SVM Algorithm. International Conference on Cyber Security and Computer Science (ICONCS 2023), (s. 41-42). Karabük Üniversitesi. <https://iconcs.karabuk.edu.tr/yuklenen/dosyalar/12619102023110135.pdf>

Bansal, M., Goyal, A., & Choudhary, A. (2022). A comparative analysis of K-nearest neighbor, genetic, support vector machine, decision tree, and long short term memory algorithms in machine learning. Decision Analytics Journal, 3, 100071. [DOI: 10.1016/j.dajour.2022.100071]

Bentéjac, C., Csörgő, A., & Martínez-Muñoz, G. (2021). A comparative analysis of gradient boosting algorithms. Artificial Intelligence Review, 54, 1937-1967. [DOI: 10.1007/s10462-020-09896-5]

Beskovylny, A. N., Stel'makh, S. A., Shcherban', E. M., et al. (2022). Concrete strength prediction using machine learning methods CatBoost, k-nearest neighbors, support vector regression. Applied Sciences, 12(21), 10864. [DOI: 10.3390/app122110864]

Chordiya, S., Sardhara, A., Thite, S., & Patil, K. (2025). Edible Oil Seed Dataset (V2). Mendeley Data. [DOI: 10.17632/x7h34tkwcp.2]

Cihan, Y., & Kuzu, A. (2020). Makine Öğrenmesi Sınıflandırma Algoritmalarının Performans Karşılaştırması. Journal of Research in Engineering and Technology, 6(2), 52-60. <https://dergipark.org.tr/pub/jret/issue/57306/795173>

Çelik, T., Görgün, A. N., & Şahin, B. (2020). Identification of sesame varieties by using machine learning algorithms and image processing. Journal of Food Processing and Preservation, 44(4), e14811. [DOI: 10.1111/jfpp.14811]

Elhassouny, A., & Smarandache, F. (2019). SqueezeNet-based classification model for image recognition. Journal of Advanced Research in Dynamical and Control Systems, 11(4), 163-170. <http://www.iardcs.org/abstract.php?id=805>

Fahim, H. A., Hasan, M. A., Bijoy, M. H. I., Reza, A. W., & Arefin, M. S. (2023). Seeds Classification Using Deep

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

- Neural Network: A Review. In: Intelligent Computing and Optimization (pp. 168-182). Springer Nature Switzerland. [DOI: 10.1007/978-3-031-50330-6_17]
- Gnyawali, D., W. D. S., Ranjan, A., Leblanc, H. A., Dunne, J. C., & Ojha, A. (2022). Deep learning for non-invasive classification of viable pollen. *Computers and Electronics in Agriculture*, 197, 106920. [DOI: 10.1016/j.compag.2022.106920]
- Gu, Y., Li, Y., Fan, S., Zhang, C., Li, H., & Huang, X. (2024). Grade Classification of Camellia Seed Oil Based on Hyperspectral Imaging Technology and Feature Fusion. *Foods*, 13(11), 1674. [DOI: 10.3390/foods13111674]
- Gulzar, Y., Hamid, Y., Soomro, A. B., Alwan, A. A., & Journaux, L. (2020). A Convolution Neural Network-Based Seed Classification System. *Symmetry*, 12(12), 2018. [DOI: 10.3390/sym12122018]
- Haq, N., & Shah, J. A. (2021). SqueezeNet-Based Deep Learning Model for Cereal Seed Classification. *Journal of Food Quality*, 2021, 6698650. [DOI: 10.1155/2021/6698650]
- Hossin, M., & Sulaiman, M. N. (2015). A review on evaluation metrics for data classification evaluations. *International Journal of Data Mining & Knowledge Management Process*, 5(3), 1–11. [DOI: 10.5121/ijdmkp.2015.5301]
- Hwang, J., Lee, M. J., Cho, Y. K., Kim, G., & Mo, C. (2024). Hyperspectral imaging with machine learning for classification of edible vegetable oils: A comparison with fatty acid composition analysis. *Food Control*, 165, 110515. [DOI: 10.1016/j.foodcont.2024.110515]
- Jha, K., Doshi, A., Patel, P., & Shah, M. (2019). A comprehensive review on automation in agriculture using artificial intelligence. *Journal of Artificial Intelligence, Machine Learning and Soft Computing*, 6(1), 1-12. [DOI: 10.5281/zenodo.2636400]
- Jun, J. P. (2021). Random forest. In *Ensemble Learning: Pattern Classification Using Ensemble Methods* (pp. 145-163). CRC Press. [DOI: 10.1201/9781003102371-8]
- Jung, Y. S. (2018). Multiple predicting K-fold cross-validation for model selection. *Journal of Nonparametric Statistics*, 30(2), 474-490. [DOI: 10.1080/10485252.2018.1453260]
- Kamilaris, A., & Prenafeta-Boldú, F. X. (2018). Deep learning in agriculture: A survey. *Computers and Electronics in Agriculture*, 147, 70–90. [DOI: 10.1016/j.compag.2018.02.016]
- Kamilaris, A., & Prenafeta-Boldú, F. X. (2021). Data augmentation and preprocessing in deep learning for agriculture: A systematic survey. *Computers and Electronics in Agriculture*, 185, 106275. [DOI: 10.1016/j.compag.2021.106275]
- Koklu, M., Sarigil, S., & Ozbek, O. (2021). The use of machine learning methods in classification of pumpkin seeds (*Cucurbita pepo* L.). *Genetic Resources and Crop Evolution*, 68, 2713–2726. [DOI: 10.1007/s10722-021-01226-0]
- Koklu, M., Cinar, I., & Taspınar, Y. S. (2021). Classification of sunflower seeds using machine learning. *Journal of Food Process Engineering*, 44(7), e13673. [DOI: 10.1111/jfpe.13673]
- Koklu, M., & Ozkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. *Computers and Electronics in Agriculture*, 174, 105507. [DOI: 10.1016/j.compag.2020.105507]
- Milanez, K. D. T. M., & Pontes, M. J. C. (2014). Classificação de óleos vegetais comestíveis usando imagens digitais e técnicas de reconhecimento de padrões [Master Tezi, Universidade Federal da Paraíba]. Repositório Institucional da UFPB. <https://repositorio.ufpb.br/jspui/handle/tede/7157>
- Mina, K. B. M., Kannan, M. S. M., Keerthana, M. M., Divya, N. J., & Kaviya, S. (2022). A Comparative Analysis of Pre-Trained Deep Learning Models for Seed Classification. 2022 13th International Conference on Computing Communication and Networking Technologies (ICCCNT). [DOI: 10.1109/ICCCNT54827.2022.9860975]
- Natekin, A., & Knoll, A. (2013). Gradient boosting machines, a tutorial. *Frontiers in Neurobotics*, 7, 21. [DOI: 10.3389/fnbot.2013.00021]

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Pandiar, M. G., Thiyagarajan, R., & Dhandapani, M. (2023). A Comparison of Deep Learning Models for Medical Image Classification. *Journal of Health Informatics*, 10(1), 18. [DOI: 10.3390/jhc.2023.100018]

Pasha, M. A., Farooq, U., & Akram, S. (2022). A novel deep learning-based hybrid model for wheat seed classification. *Computers and Electronics in Agriculture*, 199, 106887. [DOI: 10.1016/j.compag.2022.106887]

Prati, R. C., Batista, G. E. A. P. A., & Monard, M. C. (2011). A systematic study of the metrics used to evaluate the performance of supervised learning algorithms. *IEEE Transactions on Knowledge and Data Engineering*, 23(7), 963–977. [DOI: 10.1109/TKDE.2010.158]

P. R, B. R., K. P, P., K, T., D, N., & A, M. (2021). Performance Analysis of InceptionV3 and MobileNetV2 in Seeds Classification. 2021 5th International Conference on Computing Methodologies and Communication (ICCMC). [DOI: 10.1109/ICCMC51019.2021.9418246]

Ramaneswaran, R., Kaviya, P., & Manjula, D. (2021). A comparison of deep learning models: VGG16, ResNet50 and InceptionV3 for image classification. *International Journal of Engineering Research & Technology*, 10(10). [DOI: 10.17577/IJERTV10IS100238]

Ramdani, M., & Furqon, M. (2022). Comparative Analysis of Support Vector Machine and Random Forest Algorithm for Classification. *International Journal of Informatics, Telecommunication, and Electronic Engineering (IJITEE)*, 6(1), 12-16. http://www.ijitee.org/download/4_IJITEE-02-02-2022.pdf

Sam, S., Singh, A. K., & Singh, S. K. (2019). A Comparative Study of AlexNet, VGG16, and Inception-v3 for Image Classification. *International Journal of Recent Technology and Engineering (IJRTE)*, 8(4), 8196-8200. [DOI: 10.35940/ijrte.d8249.118419]

Shah, A. A., Badruddin, N., Badshah, H., & Ghani, M. A. (2023). A Comparative Analysis of VGG16, InceptionV3, and SqueezeNet for Brain Tumor Detection. *International Journal of Advanced Computer Science and Applications*, 14(7). [DOI: 10.14569/IJACSA.2023.0140723]

Sharma, R., Kamthania, M., & Kumar, S. (2023). A review of computer vision and machine learning applications in food and agriculture. *Multimedia Tools and Applications*, 82(22), 34673–34723. [DOI: 10.1007/s11042-023-14971-4]

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for deep learning. *Journal of Big Data*, 6(1), 60. [DOI: 10.1186/s40537-019-0197-0]

Singh, N. P., & Singh Rana, R. P. (2024). A Systematic Review of Machine Learning Based Classification and Prediction Models for Grains (Maize). 2024 First International Conference on Data, Engineering, and Applications (IDEA). [Semantic Scholar Link: <https://www.semanticscholar.org/paper/f91b048d4917de015de9803cfa3fa5bc64598b8a>]

Sitaula, C., & Hossain, M. B. (2021). A comprehensive survey on transfer learning for deep learning-based medical image analysis. *IEEE Access*, 9, 26868-26892. [DOI: 10.1109/ACCESS.2021.3057375]

Syed, A. (2011). Cross-Validation. In: Sammut, C., Webb, G.I. (eds) *Encyclopedia of Machine Learning*. Springer, Boston, MA. [DOI: 10.1007/978-0-387-30164-8_198]

Tamina, S. (2019). Transfer Learning using VGG-16 for Image Classification. *International Journal of Computer Science and Engineering*, 7(2), 668–673. [DOI: 10.26438/ijcse/v7i2.668673]

Tulasi, Y., Prasad, D. V., & P. V, P. K. (2021). Implementation of an Efficient and Low Computational Deep Learning Model SqueezeNet for Image Classification. *International Journal of Computer Science and Engineering (IJCSE)*, 9(3), 208–215. [DOI: 10.26438/ijcse/v9i03.208215]

Verma, A. (2022). A Review on VGG-16 Network Architecture. *International Journal of Engineering Research & Technology (IJERT)*, 11(01). <https://www.ijert.org/a-review-on-vgg-16-network-architecture>

Wang, Y., Zhuang, H., & Yoon, S. C. (2022). Variety identification of peanut seeds using hyperspectral imaging and machine learning. *Journal of Food Composition and Analysis*, 109, 104618. [DOI: 10.1016/j.jfca.2022.104618]

Wu, Y., Liu, G., Li, Z., & Gao, D. (2021). A review of machine learning techniques for seed classification and

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

quality assessment. Journal of Food Science and Technology, 58(11), 4967–4980. [DOI: 10.1007/s13197-021-05045-8]

Yates, R. K., Turner, M. A., & Moore, J. H. (2023). A practical comparison of cross-validation techniques for machine learning in genomic data. PeerJ, 11, e14766. [DOI: 10.7717/peerj.14766]

Zhang, T., Wang, Y., Zhang, H., Wang, J., & Li, M. (2023). Classification of six common edible oil seeds based on machine vision and deep learning. Food Science and Technology, 43. [DOI: 10.1590/fst.130922]

Zhu, Z., Chen, M., & Zhu, X. (2023). Soybean seed variety identification based on machine learning using image features. Archives of Agronomy and Soil Science, 70(7), 1019–1035. [DOI: 10.1080/03650340.2023.2209476]