

TOHUM SINIFLANDIRMA PROJESİ

Hibrit Derin Öğrenme + Makine Öğrenmesi Yaklaşımı

Teknik Dokümantasyon Raporu

Hazırlayan: Öğrenci Adı Soyadı

Ders: Makine Öğrenmesi / Görüntü İşleme

Tarih: Nisan 2025

VGG16 • InceptionV3 • SVM • Random Forest • KNN • Gradient Boosting • YSA

1. PROJE ÖZETİ

Bu proje, tohum görüntülerini otomatik olarak sınıflandırmak amacıyla Hibrit Derin Öğrenme + Makine Öğrenmesi (DL+ML) yöntemi kullanmaktadır. Sistem; VGG16 ve InceptionV3 gibi önceden eğitilmiş derin öğrenme modelleri aracılığıyla tohum görüntülerinden yüksek seviyeli özellikler çıkarmakta, ardından bu özellikler SVM, Random Forest, KNN, Gradient Boosting ve Yapay Sinir Ağları gibi geleneksel makine öğrenmesi sınıflandırıcılarına beslenmektedir.

Projenin Temel Amacı

Altı farklı tohum türünü (Siyah Susam, Yer Fıstığı, Hardal Tohumu, Soya Fasulyesi, Ayçiçeği, Beyaz Susam) yüksek doğrulukla sınıflandıran otonom bir görüntü analiz sistemi geliştirmek.

Parametre	VGG16 Hibrit	InceptionV3 Hibrit	Açıklama
Giriş Boyutu	224×224×3	224×224×3	RGB görüntü
Özellik Boyutu	512	2048	GAP sonrası
Çapraz Doğrulama	10-Katlı	10-Katlı	Stratified CV
Sınıf Sayısı	6	6	Tohum türü

2. VERİ SETİ VE ÖN İŞLEME

2.1 Veri Seti

Proje altı farklı tohum türüne ait görüntülerden oluşan bir veri seti üzerinde gerçekleştirilmiştir. Her sınıf için farklı miktarda görüntü bulunmakta olup aşağıdaki tabloda sınıf başına düşen örnek sayıları özetlenmektedir.

#	Sınıf Adı	Örnek Sayısı (approx.)	Açıklama
1	BLK_Sesame_Seeds	363	Siyah Susam Tohumu
2	Groundnut	595	Yer Fıstığı
3	Mustard_seeds	284	Hardal Tohumu
4	Soyabeen_Seeds	305	Soya Fasulyesi
5	Sunflower_Seeds	328	Ayçiçeği Tohumu
6	Wht_Sesame_Seeds	148	Beyaz Susam Tohumu

2.2 Ön İşleme Adımları (preprocessing.py)

Görüntüler işleme sokululmadan önce üç temel dönüşüm uygulanmaktadır:

- Yeniden Boyutlandırma: Tüm görüntüler 224×224 piksel boyutuna getirilmiştir. Bu boyut hem VGG16 hem de InceptionV3 mimarisinin beklediği standart giriş boyutudur.

- Gaussian Bulanıklaştırma: Görüntü gürültüsünü azaltmak ve kenar yumuşatma sağlamak amacıyla 3×3 çekirdek boyutlu Gaussian filtresi uygulanmıştır.
- Normalizasyon: Piksel değerleri [0,1] aralığına normalize edilmiştir (/ 255.0). Bu işlem, derin öğrenme modellerinin daha kararlı çalışmasını sağlamakta ve gradyan patlaması sorununu önlemektedir.

```
# preprocessing.py - Temel işlem akışı
img = cv2.imread(img_path)
img = cv2.resize(img, (224, 224))      # Boyut standardizasyonu
img = cv2.GaussianBlur(img, (3, 3), 0)  # Gürültü giderme
img = img.astype('float32') / 255.0     # Normalizasyon
```

3. SİSTEM MİMARİSİ

Sistem üç ana katmandan oluşan bir boru hattı (pipeline) yapısına sahiptir:

Aşama	Modül	Girdi	Çıktı
1	Ön İşleme	Ham görüntü dosyaları	224×224 .npy dizileri
2	Özellik Çıkarımı	İşlenmiş .npy dizileri	Özellik vektörleri (.npy)
3	ML Sınıflandırma	Özellik vektörleri	Sınıflandırma sonuçları (.csv)

3.1 Derin Öğrenme Modelleri (feature_extraction.py)

VGG16

Oxford Üniversitesi tarafından geliştirilen VGG16, 16 katmanlı derin evrimsel sinir ağı mimarisine sahiptir. ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklar kullanılmış, üst katmanlar çıkarılmış (include_top=False) ve Global Average Pooling ile 512 boyutlu özellik vektörü elde edilmiştir.

InceptionV3

Google tarafından geliştirilen InceptionV3, çok ölçekli evrim bloklarından (Inception modules) oluşmaktadır. Aynı şekilde ImageNet ağırlıkları kullanılmış, Global Average Pooling sonrasında 2048 boyutlu daha zengin bir özellik vektörü üretmektedir.

```
# Özellik çıkarım katmanı (feature_extraction.py)
base_model = VGG16(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
model = Model(inputs=base_model.input,
               outputs=GlobalAveragePooling2D()(base_model.output))
# InceptionV3 için aynı yaklaşım → 2048 boyutlu çıktı
```

3.2 Makine Öğrenmesi Sınıflandırıcıları

Çıkarılan özellik vektörleri aşağıdaki beş ML algoritmasına girdi olarak verilmektedir:

Algoritma	Hiperparametre	Açıklama
SVM (Destek Vektör Makinesi)	Kernel: linear	Özellik uzayında hiper-düzlem ile ayırım
Random Forest	n_estimators=100	100 karar ağacından oluşan topluluk modeli
KNN	k=3	En yakın 3 komşuya dayalı sınıflandırma
Gradient Boosting	n_estimators=50	Artımsal ağaç topluluk yöntemi
YSA (MLP)	max_iter=500/1000	Tam bağlantılı yapay sinir ağı

4. MODEL DEĞERLENDİRME YÖNTEMİ

Tüm modeller 10-Katlı Çapraz Doğrulama (10-Fold Cross Validation) yöntemi ile değerlendirilmiştir. Bu yöntemde veri seti 10 eşit parçaya bölünmekte; her iterasyonda 9 parça eğitim, 1 parça test için kullanılmakta ve süreç 10 kez tekrarlanarak sonuçların ortalaması alınmaktadır.

Neden 10-Katlı Çapraz Doğrulama?

Veri setinin tamamından maksimum düzeyde yararlanılmasını sağlar. Her örnek bir kez test verisi olarak kullanılır, bu da modelin genel performansının daha güvenilir biçimde tahmin edilmesini mümkün kılar ve aşırı öğrenme (overfitting) riskini azaltır.


4.1 Değerlendirme Metrikleri

Metrik	Formül	Anlamı
Accuracy	$(TP+TN)/(TP+TN+FP+FN)$	Genel doğru sınıflandırma oranı
Precision	$TP/(TP+FP)$	Pozitif tahminlerin doğruluk oranı
Recall	$TP/(TP+FN)$	Gerçek pozitiflerin yakalanma oranı
F1-Score	$2 \times (P \times R) / (P + R)$	Precision ve Recall'ın harmonik ortalaması

5. HATA MATRİSİ ANALİZLERİ

Hata matrisleri (Confusion Matrix), modelin hangi sınıfları doğru, hangilerini yanlış tahmin ettiğini görsel olarak ortaya koymaktadır. Diyagonaldeki değerler doğru sınıflandırmaları, diyagonal dışındaki değerler ise hatalı sınıflandırmaları göstermektedir.

5.1 InceptionV3 + SVM Hibrit Modeli



Şekil 1: InceptionV3 + SVM Hibrit Modeli Hata Matrisi


Matris incelendiğinde modelin büyük çoğunlukla doğru sınıflandırma yaptığı görülmektedir.

Gözlemlenen başlıca hatalar:

- Groundnut sınıfından 2 örnek Soyabeen_Seeds olarak yanlış sınıflandırılmıştır.
- Mustard_seeds sınıfından 3 örnek BLK_Sesame_Seeds ve 1 örnek Sunflower_Seeds olarak yanlış tahmin edilmiştir.
- Sunflower_Seeds sınıfından 1 örnek BLK_Sesame_Seeds ile karıştırılmıştır.
- Soyabeen_Seeds sınıfından 6 örnek Groundnut ile karıştırılmıştır.

Sınıf	Toplam Örnek	Doğru	Hatalı
BLK_Sesame_Seeds	363	363	0
Groundnut	595	593	2
Mustard_seeds	284	280	4
Soyabeen_Seeds	305	299	6
Sunflower_Seeds	328	327	1
Wht_Sesame_Seeds	148	148	0

5.2 VGG16 + SVM Hibrit Modeli



Şekil 2: VGG16 + SVM Hibrit Modeli Hata Matrisi

VGG16+SVM modeli de oldukça yüksek doğruluk sergilemektedir. Temel hatalar:

- BLK_Sesame_Seeds sınıfından 7 örnek Mustard_seeds olarak yanlış sınıflandırılmıştır (InceptionV3'e kıyasla daha fazla).
- Mustard_seeds sınıfından 6 örnek BLK_Sesame_Seeds ve 1 örnek Groundnut olarak yanlış tahmin edilmiştir.
- Soyabeen_Seeds sınıfından 1 örnek Groundnut ile karıştırılmıştır.
- Sunflower_Seeds ve Wht_Sesame_Seeds sınıfları her iki modelde de mükemmel sınıflandırılmıştır.

Sınıf	Toplam Örnek	Doğru	Hatalı
BLK_Sesame_Seeds	363	356	7
Groundnut	595	595	0
Mustard_seeds	284	277	7
Soyabeen_Seeds	305	304	1
Sunflower_Seeds	328	328	0
Wht_Sesame_Seeds	148	148	0

5.3 İki Modelin Karşılaştırmalı Analizi

İki hibrit modeli karşılaştırdığımızda InceptionV3+SVM kombinasyonunun genel olarak daha başarılı olduğu görülmektedir. Toplam hatalı sınıflandırma sayısı InceptionV3+SVM için 13 iken VGG16+SVM için 15'tir. Özellikle BLK_Sesame_Seeds ile Mustard_seeds arasındaki renk ve şekil benzerliği her iki modelde de temel hata kaynağı olmaktadır.

6. KOD YAPISI VE AÇIKLAMASI

6.1 preprocessing.py — Görüntü Ön İşleme

Preprocessor sınıfı ham veri dizinini tarayarak her sınıf için ayrı klasör oluşturur. Her görüntü için sırasıyla boyutlandırma, bulanıklaştırma ve normalizasyon adımları uygulanır; işlenmiş veriler NumPy (.npy) formatında kaydedilir. Bu format, görüntüleri tekrar okurken yeniden işleme ihtiyacını ortadan kaldırarak eğitim sürecini önemli ölçüde hızlandırır.

6.2 feature_extraction.py — Özellik Çıkarımı

FeatureExtractor sınıfı, belirtilen DL modelini (VGG16 veya InceptionV3) ImageNet ağırlıkları ile yükler ve üst FC katmanlarını çıkararak özellik çıkarıcı olarak kullanır. Global Average Pooling katmanı, farklı boyutlardaki özellik haritalarını sabit uzunluklu bir vektöre dönüştürür. Tüm görüntülerin özellikleri bir arada tek bir .npy dosyasına kaydedilir.

6.3 ml_classifiers.py — Ana ML Eğitim Modülü

MLTrainer sınıfı her iki DL modeli için (VGG16 ve InceptionV3) ML sınıflandırıcılarını eğitir. cross_validate fonksiyonu ile 10-katlı CV uygulanır; n_jobs=-1 parametresi ile paralel işleme etkinleştirilerek eğitim süresi kısaltılır. Sonuçlar CSV formatında kaydedilir.

6.4 ml_inv3_classifiers.py — InceptionV3 Özel Modülü

Bu modül yalnızca InceptionV3 özelliklerini işlemek üzere optimize edilmiş alternatif bir eğitim modülüdür. Gradient Boosting için n_estimators değeri 50'ye düşürülmüş, MLP için max_iter 500'e ayarlanmıştır; bu sayede işlem süresi azaltılmıştır.

7. BULGULAR VE SONUÇLAR

7.1 Genel Performans Değerlendirmesi

Hata matrisi analizlerinden elde edilen bulgular şu şekilde özetlenebilir:

- InceptionV3+SVM hibrit modeli, VGG16+SVM modeline kıyasla daha az hata yapmakta ve daha yüksek genel doğruluk sergilemektedir.
- Her iki modelde de Sunflower_Seeds ve Wht_Sesame_Seeds sınıfları %100 doğrulukla sınıflandırılmıştır.

- Groundnut sınıfı, sahip olduğu en yüksek örnek sayısı (595) ile birlikte her iki modelde de başarıyla sınıflandırılmıştır.
- BLK_Sesame_Seeds ile Mustard_seeds arasındaki görsel benzerlik her iki modelde de temel hata kaynağını oluşturmaktadır.
- Wht_Sesame_Seeds sınıfının diğerlerine oranla daha az örneğe sahip olmasına (148) karşın mükemmel sınıflandırılması, özellik çıkarımının etkinliğini göstermektedir.

7.2 Model Karşılaştırması

Kriter	InceptionV3 + SVM	VGG16 + SVM
Özellik Boyutu	2048	512
Toplam Hata	13	15
Tahmini Doğruluk	~%99.4	~%98.9
En Problemlili Sınıf	Soyabeen_Seeds (6 hata)	BLK_Sesame & Mustard (14 hata)
Mükemmel Sınıflar	BLK, Sunflower, Wht	Groundnut, Sunflower, Wht
Genel Öneri	✓ Tercih Edilir	Kabul Edilebilir

7.3 Geliştirme Önerileri

1. Veri Artırma (Data Augmentation): Özellikle az örnekli Wht_Sesame_Seeds sınıfı ve hata oranı yüksek sınıflar için döndürme, çevirme, parlaklık değişimi gibi augmentation teknikleri uygulanabilir.
2. Hiperparametre Optimizasyonu: SVM için RBF kernel, Random Forest için farklı ağaç sayıları ve KNN için farklı k değerleri GridSearchCV ile optimize edilebilir.
3. Ensemble Yöntemleri: En başarılı birkaç modelin tahminleri oylama (voting) veya yığma (stacking) ile birleştirilerek daha güçlü bir hibrit sistem oluşturulabilir.
4. SqueezeNet Entegrasyonu: Daha hafif mimari olan SqueezeNet özellik çıkarıcı olarak eklenerek hesaplama maliyeti düşürülmüş alternatif bir sistem sunulabilir.

8. SONUÇ

Bu projede tohum görüntülerini sınıflandırmak amacıyla geliştirilen Hibrit DL+ML yaklaşımı son derece başarılı sonuçlar üretmiştir. Derin öğrenme modellerinin güçlü özellik çıkarımı kapasitesi ile geleneksel makine öğrenmesi algoritmalarının yorumlanabilir ve hızlı sınıflandırma yetenekleri bir arada kullanılmıştır.

InceptionV3+SVM kombinasyonu yaklaşık %99.4 doğruluk oranıyla en başarılı sonucu vermiş; VGG16+SVM ise %98.9 ile güçlü bir alternatif oluşturmuştur. 10-Katlı Çapraz Doğrulama yöntemi, elde edilen performans değerlerinin güvenilirliğini güvence altına almaktadır.

Temel Çıkarım

Hibrit DL+ML yaklaşımı, özellikle görsel açıdan benzer sınıfları birbirinden ayırt etme konusunda son derece etkili bir yöntem olduğunu kanıtlamıştır. Sistem, gerçek dünya tarım uygulamalarında tohum kalite kontrolü ve otomatik sınıflandırma için kullanılabilir düzeye getirilmiştir.